

AI 工具使用详情

1 所用 AI 工具名称和版本

- 1.Deepseek V3
- 2.豆包 2024.05 核心能力基线版

2 具体使用目的和环节

- 1.搜索算法模型，并自行判断其对于带解决问题的适配性
- 2.对于不熟悉库与代码进行询问以便利用其进行算法编写

3 关键交互记录（重要提示词与回复）

3.1 问题一

Q: 如何解读 GAMM 模型中“Y 浓度与 BMI、孕周关系”的输出结果？

A: 先看模型基础信息，如“Family: gaussian”表示 Y 浓度服从正态分布，“Link function: identity”说明直接建模均值；参数系数中，截距项显著 ($p_i 2e-16$) 代表存在 Y 浓度的基础水平；平滑项里，s (BMI) 和 s (Gestational_days) 的 p 值 < 0.05 ，说明二者对 Y 浓度的非线性效应显著，edf 值越大非线性越强；拟合优度看调整后 R^2 (如 0.753) 和偏差解释率 (如 81%)，数值越高模型拟合效果越好。

Q: 用 GAMM 建模时，如何选择“连接函数”？

A: 连接函数的选择取决于因变量（响应变量）的类型：若因变量是连续型（如 Y 染色体浓度、血压），选“identity”（恒等连接），直接建模均值；若因变量是二分类（如是否患病、是否购买），选“logit”（逻辑连接），建模概率的对数优势比；若因变量是计数型（如发病次数、点击次数），选“log”（对数连接），建模速率的对数。

Q: 用 GAMM 分析二元关系时，如何判断“非线性效应是否显著”？

A: 主要看 GAMM 输出结果中“平滑项的近似显著性”部分：对于“s(x)”，首先看 p 值，若 $p_i 0.05$ (如 $p_i 2e-16$)，说明平滑效应（非线性效应）显著；其次看有效自由度 (edf)，若 $edf_i 1$ ，说明二元的关系是非线性的 (edf 值越大，非线性程度越强)，若 $edf \approx 1$ ，则接近线性关系，可考虑用线性模型替代。

Q: GAMM 模型的“拟合优度指标”有哪些？分别代表什么含义？

A: 主要有两个核心指标: 一是“调整后 R^2 (R-sq.(adj))”, 它衡量模型能解释因变量变异的比
例, 如 0.753 表示模型解释了 Y 浓度 75.3% 的变异, 该值越高拟合越好; 二是“偏差解释率 (Deviance
explained)”, 偏差是衡量模型预测值与真实值差异的指标, 偏差解释率越高, 说明模型对数据偏差的
解释能力越强, 如 81% 表示模型解释了 81% 的偏差。

3.2 问题二

Q: 肘部法则是什么? 它的核心作用是什么?

A: 肘部法则是聚类分析 (如 K-Means) 中确定最优聚类数的启发式方法。核心是计算不同聚类
数 K 对应的组内平方和 (WCSS), 绘制“K-WCSS” 曲线, 找到 WCSS 下降速率由快转慢的“肘
部”(拐点), 该拐点对应的 K 即为最优聚类数, 可平衡聚类效果与计算成本, 避免过度聚类或聚类不
足。

Q: 用肘部法则确定 K 值的具体步骤是什么?

A: 第一步, 对聚类变量做标准化 (消除量纲影响); 第二步, 遍历 K=1 到 K=10 (或根据业务设
定范围), 每个 K 训练 K-Means 模型并记录 WCSS; 第三步, 绘制“K-WCSS” 曲线; 第四步, 找到
曲线中 WCSS 下降由快转慢的拐点, 该拐点对应的 K 就是最优聚类数, 如 K=3 时曲线从快速下降转
为平缓, 即选 K=3。

3.3 问题三

Q: 用肘部法则确定 K 值时, 为什么要对“聚类变量做标准化”?

A: 因为聚类算法 (如 K-Means) 是基于“距离” 计算的, 若变量的量纲不同, 量纲大的变量会
主导距离计算, 影响聚类结果。例如, “身高 (cm, 数值范围 150-190)” 和 “体重 (kg, 数值范围
40-100)”, 若不标准化, 身高的数值差异 (40) 远小于体重的数值差异 (60), 但实际二者对聚类的重要
性可能相同, 标准化后 (将变量转为均值 0、标准差 1), 可消除量纲影响, 让各变量在聚类中发挥
同等作用。

3.4 问题四

Q: 数学建模中的“shaq” 可能指什么?

A: 结合建模场景, “shaq” 更可能是拼写偏差, 对应 SHA (安全哈希算法)。SHA 是密码学中的
哈希函数, 能将任意长度数据转为固定长度哈希值, 在建模中可用于敏感数据脱敏 (如用哈希值替换
患者身份证号)、数据完整性校验 (比对哈希值判断数据是否被篡改)、高维数据特征压缩 (将文本转
为哈希值降维), 常见于医疗、金融等需数据安全的建模场景。

Q: 随机森林中“Bootstrap 抽样” 的具体过程是什么?

A: Bootstrap 抽样是有放回的抽样方式, 具体过程为: 假设原始训练集有 N 个样本, 每次从 N
个样本中随机抽取 1 个样本, 记录后将其放回原始样本集, 重复该过程 N 次, 得到一个包含 N 个
样本的子样本集 (部分样本可能被多次抽取, 部分样本可能未被抽取)。每棵决策树都基于一个通过
Bootstrap 抽样得到的子样本集训练, 这保证了树与树之间的差异性。

Q: 随机森林适合哪些建模场景?

A：适合分类和回归两类场景。分类场景如客户流失预测（判断客户是否会流失）、疾病诊断（根据体检指标判断是否患病）；回归场景如房价预测（结合面积、地段等预测房价）、销量预测（根据广告投入、季节等预测销量）。此外，还可用于特征重要性分析，筛选对结果影响最大的变量，辅助模型优化。

Q：点二列相关系数与“二列相关系数”的区别是什么？

A：核心区别在于二分变量的类型：点二列相关系数适用于“真正二分变量”，即变量本身就是二分的（如性别、是否患病），不是由连续变量人为划分的；二列相关系数适用于“人为二分变量”，即变量原本是连续的，后被人为划分为二分（如将“成绩”划分为“及格 / 不及格”，将“收入”划分为“高收入 / 低收入”）。此外，点二列相关系数的计算公式更简单，二列相关系数则需用到连续变量的正态分布假设。

4 采纳和人工修改情况