

数学建模比赛

摘要

本文针对NIPT（无创产前检测）技术中最佳检测时点选择与胎儿异常判定的问题，通过建立数学模型，对孕妇进行合理分组并确定最佳检测策略，以最小化潜在风险并提高检测准确性。我们综合利用了数理统计等方法，系统地解决了题目提出的四个问题。

针对问题一，本文首先进行了数据探索与预处理，通过散点图初步发现Y浓度随孕周呈上升趋势，与BMI的关系则需进一步建模验证。为解决个体重复测量数据中的组内相关性并准确捕捉变量间潜在的非线性关系，我们分别建立了**线性混合模型（LMM）**、**非线性混合模型（NLME）**和**广义可加混合模型（GAMM）**。综合比较表明，GAMM具有最优的拟合性能能同时识别孕周和BMI的显著非线性影响，并验证了个体间存在显著差异。最终基于GAMM得出结论：Y染色体浓度随孕周呈非线性增长，而与BMI之间存在复杂的非线性负相关关系，为该类数据的分析提供了稳健的建模框架。

针对问题二，本研究基于临床已知的男胎孕妇BMI是影响胎儿Y染色体浓度达标时间的主要因素，通过对孕妇BMI进行科学分组并确定最佳NIPT检测时点，以最小化孕妇潜在风险。首先，我们依据Y染色体浓度达标情况将孕妇分为三组：始终达标组、中间达标组和从不达标组；接着采用**K-means聚类算法**对孕妇平均BMI进行聚类分析，通过**肘部法则**确定最佳聚类数为5类；然后计算每个BMI区间的Y染色体浓度达标时间，以中位数确定该组最佳检测时点；最后通过**误差传播模型**分析检测误差对结果的影响。结果表明，基于BMI分组的个性化检测时点推荐能够有效降低临床风险，为NIPT临床实践提供了科学依据。

针对问题三，本研究在问题二基础上进一步引入年龄、身高、体重等多因素，系统分析其对男胎Y染色体浓度达标时间的影响。通过多参数聚类与天数-BMI聚类方法的对比，最终选定天数-BMI聚类法将孕妇分为5个具有明确临床意义的BMI区间。基于**Kaplan-Meier生存分析**构建累积达标函数，结合早期检测效用与晚期检测风险函数，建立总效用最小化模型以确定各分组最优NIPT检测时点。采用随机森林与线性回归量化各因素对达标时间的影响强度，并通过**SHAP值增强模型**可解释性。误差分析表明，模型在5%检测误差下仍保持良好稳定性，尤其高BMI组需更宽时间窗口。最终提出基于BMI分层的个性化检测策略，显著降低临床风险。

针对问题四，本研究致力于构建女胎染色体非整倍体（T21、T18、T13）异常判定模型。通过严格数据质控与特征筛选，选取15个关键特征（包括Z值、GC含量、读段数比例、BMI等），并采用**SMOTEENN混合采样算法**处理类别不平衡问题。系统比较**随机森林**、**XGBoost**和**SVM**三种模型，最终选定随机森林作为最优分类器，并通过网格搜索与交叉验证进行**超参数调优**。模型在测试集上准确率达92.5%，AUC为0.9676，表现出优异的分类性能与泛化能力。特征重要性分析显示，唯一比对的读段数、各染色体Z值为核心预测因子，与临床先验高度一致。该模型为女胎染色体异常提供了一种高效、可靠的数据驱动判定工具。

关键词：线性混合模型,非线性混合模型,广义可加混合模型, K-means聚类算法, 肘部法则, 误差传播模型, Kaplan-Meier生存分析, SHAP值增强模型, SMOTEENN混合采样算法, 随机森林, 超参数调优

一 问题重述

1.1 问题背景

NIPT (Non-invasive Prenatal Testing, 无创产前检测) 作为一项革命性的产前筛查技术, 通过采集孕妇外周血中的胎儿游离DNA进行测序分析, 能够有效评估胎儿常见染色体非整倍体异常的风险[1]。该技术具有无创、安全、准确性高等特点, 已成为临床产前筛查的重要手段。

在实际临床应用中, NIPT检测的准确性受到多种因素影响, 其中胎儿游离DNA浓度 (特别是Y染色体浓度对于男胎) 是关键因素之一。临床实践表明, 胎儿Y染色体浓度与孕妇孕周数及身体质量指数 (BMI) 存在显著相关性。同时, 检测时机的选择对于尽早发现胎儿异常、降低临床风险至关重要: 早期发现 (12周以内) 风险较低, 中期发现 (13-27周) 风险较高, 而晚期发现 (28周以后) 风险极高。

目前临床通常根据孕妇BMI值进行简单分组并确定统一的检测时点, 但这种方法未能充分考虑孕妇年龄、体重等个体差异, 可能导致部分孕妇错过最佳检测时机, 增加临床风险。因此, 需要建立更加科学、个性化的 NIPT时点选择模型, 为不同特征的孕妇群体制定最优检测策略。

1.2 问题要求

附件提供了某地区 (大多为高BMI) 孕妇的NIPT检测数据, 包括孕妇年龄、BMI、孕周数、胎儿染色体浓度、Z值、GC含量、读段数等相关指标。现需要根据这些数据建立数学模型, 解决以下问题:

问题一: 基于附件中的数据, 分析胎儿Y染色体浓度与孕妇孕周数、BMI等指标的相关特性, 建立合适的数学模型描述它们之间的关系, 并对模型的显著性进行统计检验。

问题二: 临床证明男胎孕妇的BMI是影响胎儿Y染色体浓度达标时间 (浓度 $\geq 4\%$ 的最早时间) 的主要因素。请对男胎孕妇的BMI进行合理分组, 确定每组的BMI区间和最佳NIPT检测时点, 使得孕妇的潜在风险最小, 并分析检测误差对结果的影响。

问题三: 综合考虑体重、年龄等多种因素对男胎Y染色体浓度达标时间的影响, 同时考虑检测误差和胎儿Y染色体浓度达标比例, 根据男胎孕妇的BMI进行合理分组, 确定每组的最佳NIPT检测时点, 使孕妇潜在风险最小, 并分析检测误差对结果的影响。

问题四: 针对女胎异常的判定问题, 以女胎孕妇的21号、18号和13号染色体非整倍体为判定结果, 综合考虑X染色体及上述染色体的Z值、GC含量、读段数及相关比例、BMI等因素, 建立女胎异常的判定模型和方法。

二 问题分析

2.1 问题一的分析

问题一要求分析Y染色体浓度与孕周数、BMI之间的相关关系, 由于数据来源于同一孕妇的多次检测, 存在明显的组内相关结构, 传统回归方法无法处理该类数据且会导致估计偏差。同时, 生物学背景

表明孕周与浓度间可能存在非线性增长模式，而BMI亦可能通过稀释效应产生非线性影响。因此，需采用能同时兼容个体随机效应与变量非线性关系的混合建模策略。我们首先通过个体线性回归初步探索趋势，发现普遍正增长但存在个体差异，且BMI与浓度增长率线性相关不明显，暗示简单线性假设不足。进而，分别建立LMM、NLME和 GAMM三类混合模型进行系统比较，最终依据GAMM显著的非线性识别能力和更高的拟合优度，选择其作为揭示变量间复杂相关特性的核心模型。

2.2 问题二的分析

针对问题二，其要求根据男胎孕妇的BMI进行合理分组并确定最佳检测时点。我们根据Y染色体浓度是否达标（ $\geq 4\%$ ）将孕妇分为三类，反映不同孕妇的Y染色体浓度变化规律。然后采用K-means聚类算法对孕妇平均BMI 进行客观分组，避免主观划分的随意性。通过肘部法则确定最佳聚类数为5，确保了分组的科学性和合理性。接着对于每个BMI分组，计算组内孕妇的Y染色体浓度达标时间（对于中间达标组采用插值法预测），以中位数作为该组的最佳检测时点，减少异常值影响。最后考虑检测过程中可能存在的测量误差和模型误差，通过误差传播模型评估这些误差对达标时间预测的影响程度，确保推荐时点的可靠性。

2.3 问题三的分析

问题三要求在问题二基础上引入年龄、身高、体重等多因素，并考虑检测误差与达标比例，以更全面确定男胎孕妇的最佳NIPT检测时点。难点在于多因素之间存在复杂交互效应，且数据中体重变化显著，直接使用均值会丢失动态信息。因此，本研究首先对BMI进行Z标准化，并采用多参数聚类与天数-BMI聚类两种方法进行对比。结果表明，天数-BMI聚类在聚类质量、结构稳定性和临床可解释性上均优于多参数聚类，故以其作为分组依据。随后构建多阶段建模框架，整合生存分析、效用-风险函数优化和机器学习建模（随机森林/线性回归），系统分析各因素影响，并通过蒙特卡洛模拟验证模型鲁棒性。最终实现科学分组与个性化时点推荐，为临床提供可靠决策支持。

2.4 问题四的分析

问题四要求建立女胎染色体非整倍体异常判定模型，需综合考量X、21、18、13号染色体的Z值、GC含量、读段数及相关比例、BMI等多种因素。核心挑战在于数据存在严重类别不平衡（异常样本仅占10.7%），且特征维度高、冗余性强。为此，本研究首先进行严格数据清洗与质控，剔除异常样本，并使用点二列相关系数筛选出15 个最具判别力的特征。为克服类别不平衡，引入SMOTEENN混合采样算法，有效提升少数类样本代表性。在模型选择上，系统比较随机森林、XGBoost和SVM三类主流算法，最终随机森林以其最优的综合性能（准确率、召回率、AUC等）胜出。通过超参数调优与交叉验证进一步优化模型，并结合SHAP值分析增强可解释性，确保模型结果临床可信、可用。

三 模型假设

1.假设附件所提供的孕妇NIPT检测数据真实、准确，且数据样本足以反映胎儿染色体浓度与孕妇孕周、BMI等指标间的统计规律。

- 2.假设题目中给出的Y染色体浓度4% 的临界值是可靠且普适的。
- 3.假设具有相似特征（如处于同一BMI区间）的孕妇群体，其胎儿Y染色体浓度的增长规律和达标时间具有相似的统计特征。
- 4.假设题目所提供的特征（包括但不限于X、21、18、13号染色体的Z值、GC含量、读段数比例及孕妇BMI等）包含了足以有效判别女胎染色体是否异常的信息。

四 符号说明

符号	说明
$k_i^{(c)}$	孕妇代码为 i 的个体Y染色体浓度与孕周线性回归方程斜率
$k_i^{(b)}$	孕妇代码为 i 的个体BMI指数与孕周线性回归方程斜率
Y_{ij}	孕妇代码为 i 的个体第 j 次检测得到的Y染色体浓度
G_{ij}	孕妇代码为 i 的个体第 j 次检测的检测孕周（天为单位）
BMI_i	表示第 i 个孕妇的身体质量指数（常数对于每个孕妇）

五 问题一模型建立求解

5.1 模型建立思路

问题一要求分析胎儿Y染色体浓度与孕妇孕周数和BMI等指标的相关特性。我们先观察通过分析数据，对每个人线性回归，发现了绝大多数人 y 和时间关系与 y 和增长率和BMI增长率关系，以此我们判定，所有曲线都遵循一个共同的、内在的生物学规律，但由于个体差异，曲线的高度和形状会各不相同。为精确刻画个体增长规律并避免群体平均带来的巨大偏差，我们决定采用基于个体时间序列的混合效应方法。核心思路是：首先对数据进行筛选，保证每个个体的数据点数量足以支持回归分析；然后通过使用三种线性与非线性混合效应模型，比较得出最优是GAMM，并且根据这个得出得出胎儿Y染色体浓度与孕妇孕周数和BMI的相关特性。

5.2 数据预处理

为探究Y染色体浓度与孕妇孕周数和BMI的关系，我们分别以检测孕周（天数）和BMI为x轴，Y染色体浓度为y轴，绘制了散点图（其中相同颜色的点代表同一个人），如下：




图 1: y染色体浓度散点图

分析左图（Y染色体浓度随孕周变化）可见对于一个个体而言，随着孕周从80天增加到200天，Y染色体浓度整体呈上升趋势，散点分布呈现明显的“向右上方扩散”特征。特别是在孕周大于160天后，高浓度点（ $Y \geq 0.15$ ）的出现频率显著增加，这表明Y染色体浓度与孕周之间存在正相关关系

分析右图（Y染色体浓度与BMI关系）显示，随着BMI值在20-40范围内变化，Y染色体浓度的散点分布未呈现明显的单向变化趋势。然而，结合后续模型得到的负系数估计值（ $c = -0.0042$ ），提示Y染色体浓度可能随BMI增加而轻微下降，但这种趋势在散点图中不够明显，可能需要通过模型来进一步验证。

我们打算先建立回归模型，故对于原数据处理，仅保留检测同一孕妇代码检测次数大于3次的数据，以保证建立的回归模型的可靠性。

5.3 线性回归模型

分析胎儿 Y 染色体浓度与孕妇的孕周数和 BMI 等指标的相关特性，本研究为每位孕妇建立了双变量时间序列回归模型。从预处理后的有效数据中，筛选出每位孕妇多次检测的记录，分别建立以下两个一元线性回归模型：

1. Y染色体浓度-时间关系模型：

以检测时间（ t_{ij} ）为自变量，对应的Y染色体浓度（ c_{ij} ）为因变量，建立回归模型：

$$c_{ij} = k_i^{(c)} * t_{ij} + b_i^{(c)} + \epsilon_{ij}^{(c)} \quad (1)$$

其中： $k_i^{(c)}$ 表示第 i 位孕妇的胎儿Y染色体浓度的日增长率，这是我们关注的核心参数； $b_i^{(c)}$ 为截距

项; $\epsilon_{ij}^{(c)}$ 为随机误差项。

2. BMI-时间关系模型:

以检测时间 (t_{ij}) 为自变量, 对应的Y染色体浓度 (c_{ij}) 为因变量, 建立回归模型:

$$c_{ij} = k_i^{(b)} * t_{ij} + b_i^{(b)} + \epsilon_{ij}^{(b)} \quad (2)$$

其中: $k_i^{(b)}$ 表示第 i 位孕妇的胎儿Y染色体浓度的日增长率, 这是我们关注的核心参数; $b_i^{(b)}$ 为截距项; $\epsilon_{ij}^{(b)}$ 为随机误差项。

为评估拟合优度, 我们采用最小二乘法进行参数估计, 并计算确定系数 R_i^2

5.4 Y染色体浓度与时间关系的个体分析

对于基于Y染色体浓度与时间关系建立的所有个体回归模型, 我们首先对其关键参数 (斜率, 截距, 确定系数) 进行了统计分析, 结果如下表所示:


统计量	斜率 k_i (%/天)	截距	确定系数 R_i^2
平均值	0.000800	-0.005467	0.861443
标准差	0.00316	0.038959	0.123487
最小值	0.001752	0.088208	0.999747
最大值	0.000205	-0.151320	0.505933

从表中可知, 个体的Y染色体浓度均随孕天增加呈现明显的上升趋势,绝大部分模型的拟合优度较高 (平均 $R^2 = 0.824$), 这表明线性模型能够很好地描述浓度随时间变化的规律。

5.5 BMI增长率与Y染色体浓度增长率的全局相关性分析

为探究BMI是否导致了上述增长速率的差异, 我们计算了每位孕妇的BMI增长率个体Y染色体浓度增长率 k_i 的相关性。

我们绘制了标准化BMI增长速率与斜率 k_i 在相应编号下的散点图与两者在不同维度下绘制的图像, 如下



为探究BMI是否影响Y染色体浓度的增长速率, 我们分析了每位孕妇的BMI增长率与Y染色体浓度增长率的相关性。散点图与线性拟合显示 R^2 值较小(0.113569), 拟合效果不理想, 因此需要考虑其他模型形式。

5.6 新模型选择思路

为建立能够准确描述Y染色体浓度与孕周数、BMI之间关系的数学模型，我们基于生物学机制与数据结构特征两个方面进行了综合论证，以此确定模型选择的基本方向。

1.从生物学机理出发：

题目背景与临床知识表明，胎儿游离DNA浓度（此处体现为Y染色体浓度）随孕周增加而增长。这是因为随着胎儿发育，其细胞凋亡释放到母体血液中的DNA总量增加。这种增长通常不是线性的，在早期增长缓慢，中后期可能加速，符合指数增长或逻辑增长的生物学规律。因此，我们优先考虑非线性模型来捕捉孕周与浓度的关系。

而对于BMI与Y染色体的浓度关系，较高的BMI可能意味着更多的血液量和脂肪组织，理论上会对胎儿游离DNA浓度产生一定的“稀释”效应。因此，我们假设BMI对Y染色体浓度存在一个负向影响将这一项加入模型，符合我们的生理学直觉。

2.从数据结构出发：

本研究的核心特征在于数据结构：每个孕妇有多次重复测量记录，导致数据点之间存在明显的组内相关性。若采用普通最小二乘回归，将严重违背模型独立性假设，导致参数估计偏差和标准误低估。

混合效应模型则能有效处理此类层次结构数据：通过引入刻画个体差异的随机效应，模型能够区分组内与组间变异，从而提升固定效应估计的稳健性与准确性。因此，从数据结构的角度看，混合效应模型是更适合本研究的建模框架。

5.7 混合模型建立

基于前述生物学机理与数据结构特征，本研究采用混合效应模型（Mixed-Effects Model）作为核心建模框架。该模型能有效刻画个体随机变异，区分组内与组间差异，从而提升固定效应估计的稳健性。我们分别构建以下三类模型进行系统比较：线性混合模型（LMM）、非线性混合模型（NLME）与广义可加混合模型（GAMM），详细性能对比见表1：

综合对比分析如下

5.7.1 模型复杂度与拟合优度

线性混合模型（LMM）结构简单、解释性强，但强制的线性假设可能导致对潜在非线性关系的拟合不足。非线性混合模型（NLME）通过引入指数项更好地捕捉Y浓度随孕周的增长趋势，其AIC值（-5026.9）略低于LMM，显示在复杂度调整后拟合更优，但该模型未包含BMI变量，限制了其整体解释力。广义可加混合模型（GAMM）则兼具极佳的灵活性与拟合能力，同时刻画BMI和孕周的非线性效应，其调整 R^2 达0.753，可解释81%的偏差，显著优于前两类模型。

5.7.2 孕周效应

三类模型均证实孕周对Y染色体浓度存在极显著影响（ $p \leq 0.001$ ）。特别地，GAMM中孕周平滑项的有效自由度（ $edf = 4.682$ ）显著大于1，进一步表明其与浓度之间呈显著非线性关系，也从数据层面支持了NLME中采用指数增长形式的合理性。


表 1: 三种混合建模对比分析表

特征指标	线性混合模型 (LMM)	非线性混合模型 (NLME) - 广义可加混合模型 (GAMM) 指数形式	
模型形式	$Y \sim \text{BMI} + \text{G_days} + (1 \text{Subject})$	$Y \sim a * \exp(b * \text{G_days})$	$Y \sim s(\text{BMI}) + s(\text{G_days}) + s(\text{Subject}, \text{bs}="re")$
模型复杂度/灵活性	低 (严格线性假设)	中 (预设非线性形式)	高 (数据驱动非线性形式)
固定效应 - BMI	-0.001376($p \leq 0.01$)	-	平滑项显著($p = 0.00764$)
固定效应 - 孕周	0.0004466($p \leq 0.001$)	0.0088($p \leq 0.001$)	平滑项高度显著($p \leq 2e-16$)
随机效应 - 个体方差	0.0008285(Std.Dev: 0.02878)	0.0001279(Std.Dev: 0.01131) (仅a)	包含在 s(Subject) 中 (高度显著, $p \leq 2e-16$)
残差方差	0.0002930(Std.Dev: 0.01712)	0.0002807(Std.Dev: 0.01675)	Scale est. = 0.00027726
拟合优度 - AIC	-5025.5 (REML)	-5026.912	REML = -2536.1 (与AIC/BIC不可直接比较)
拟合优度 - R^2 /解释度	-	-	Adj. $R^2 = 0.753$, Deviance Explained = 81%
核心优势	简单直观, 解释性强	捕捉指数增长趋势, 生物学解释性好	无需预设形式, 自动捕捉复杂非线性关系, 拟合优度最高
主要局限	可能忽略重要非线性关系, 拟合度相对较低	函数形式预设可能带来偏差, 未包含BMI	结果为平滑曲线, 缺乏参数化解析表达式

5.7.3 BMI效应

LMM检测到BMI存在显著的线性负效应 ($p \leq 0.01$), 而GAMM进一步揭示出BMI的影响具有显著非线性特征 (edf = 5.416, $p = 0.00764$)。这表明LMM中简单的线性设定可能不足以充分捕捉BMI在整个取值范围内对Y浓度的复杂影响模式。

此外我们分别绘制了这三者对于原散点图的拟合曲线并绘制了这三者的各自的优劣图, 如下:



综合模型对比指标与拟合图示，GAMM不仅具有最优的统计拟合性能，也能更充分捕捉变量间复杂的非线性关系，因此被选作后续建模的基础框架。

5.8 GAMM模型的建立

为充分探索胎儿Y染色体浓度与孕妇孕周数和BMI之间可能存在的复杂非线性关系，避免预设模型形式的偏差，我们建立了广义可加混合模型（Generalized Additive Mixed Model, GAMM）。该模型不强制要求变量间满足特定的参数关系（如线性或指数关系），而是通过平滑函数灵活地拟合数据中潜在的非线性模式，同时通过随机效应项处理个体重复测量数据带来的相关性。

建立GAMM模型的具体形式如下：

$$Y_{ij} = \beta_0 + s_1(BMI_i) + s_2(G_{ij}) + s_3(Subject_i) + \epsilon_{ij} \quad (3)$$

其中：

- β_0 为模型截距项
- $s_1(BMI_i)$ 为BMI的平滑函数，用于捕捉BMI对Y染色体浓度的非线性影响
- $s_2(G_{ij})$ 为孕周数的平滑函数，用于捕捉孕周对Y染色体浓度的非线性影响
- $s_3(Subject_i)$ 为针对孕妇个体的随机效应平滑项，用于捕捉个体特异性差异
- ϵ_{ij} 为残差项，假定服从正态分布： $\epsilon_{ij} \sim N(0, \sigma_\epsilon^2)$

模型采用薄板回归样条（Thin Plate Regression Splines）作为平滑函数的基础，使用REML（Restricted Maximum Likelihood）方法进行参数估计，以保证方差分量估计的无偏性。

5.9 显著性检验

对建立的GAMM模型进行全面的显著性检验，结果如下：

5.9.1 平滑项显著性检验

基于方差分析原理的显著性检验显示：

BMI平滑项 ($s_1(BMI_i)$)：有效自由度 (edf) = 5.416，参考自由度 = 6.263，F值 = 3.02，p值 = 0.00764**

- 结果表明BMI对Y染色体浓度的影响具有高度显著的非线性特征 ($p \leq 0.01$)
- edf ≥ 1 表明BMI与Y浓度间存在复杂的非线性关系，而非简单的线性关系

孕周平滑项 ($s_2(G_{ij})$)：有效自由度 (edf) = 4.682，参考自由度 = 5.711，F值 = 77.86，p值 $\leq 2e-16$ ***

- 结果表明孕周对Y染色体浓度的影响极显著 ($p \leq 0.001$)
- edf = 4.682 ≥ 1 证实了孕周与Y浓度间存在显著的非线性关系

个体随机效应项 ($s_3(\text{Subject}_i)$): 有效自由度 (edf) = 240.736, 参考自由度 = 266.000, F值 = 10.58, $p\text{值} \leq 2e-16^{***}$

- 结果表明不同孕妇个体间存在极显著的差异性 ($p \leq 0.001$)
- 证明使用混合效应模型处理重复测量数据的必要性

5.9.2 模型拟合优度检验

- 调整后 $R^2 = 0.753$, 表明模型能够解释Y染色体浓度75.3%的变异
- 偏差解释率 = 81%, 表明模型对数据偏差的解释程度较高
- 尺度参数估计值 = 0.00027726, 反映了模型的残差方差
- REML准则值 = -2536.1, 用于模型比较 (数值越小表示拟合越好)

GAMM模型的结果为后续参数化模型 (非线性混合效应模型) 的选择提供了坚实的数据驱动依据, 证实了孕周和BMI与Y染色体浓度间均存在显著的非线性关系。

六 问题二模型建立求解

6.1 数据预处理

本问题旨在探究孕妇BMI对胎儿Y染色体浓度最早达标时间的影响。考虑到同一孕妇的BMI随时间变化幅度较小 (个体内变异), 且个体间差异远大于时间变化量, 为提高分析的准确性和可靠性, 我们采用每位孕妇多次BMI 测量的平均值作为其代表值进行后续统计分析。

为合理区分样本并便于计算NIPT最佳时点, 我们依据Y染色体浓度达标情况对孕妇进行了科学分组:

- 第一组 (始终达标组): 从首次检测开始Y染色体浓度即达到或超过4%的样本。该组数据保存在 'bmi_Y_always_can_test_result.xlsx' 中, 包含孕妇代码、平均BMI和最早达标天数 (即首次检测时间)。
- 第二组 (中间达标组): 初始检测未达标但后续检测达标的样本。该组数据保存在 'bmi_Y_middle_result.xlsx' 中, 包含孕妇代码、平均BMI和预测达标天数 (通过插值法计算获得, 详见附录代码Line XX)。
- 第三组 (从不达标组): 所有检测中Y染色体浓度均未达标的样本。该组数据保存在 'bmi_Y_cannot_test_result.xlsx' 中, 包含孕妇代码、平均BMI和最晚达标天数 (即末次检测时间)。

为确保数据质量, 若某样本曾达标但后续检测又低于4%, 则视为无效样本并予以剔除。经上述处理, 最终获得有效样本总量为230例。其中, 第一组186例 (占比80.87%), 第二组37例 (占比16.09%), 第三组7例 (占比3.04%)。这一分组策略确保了后续分析的可靠性和代表性。

6.2 BMI划分与聚类分析

为探究BMI对Y染色体浓度达标时间的影响模式，我们采用聚类算法对孕妇平均BMI进行科学细分。首先，通过肘部法则确定最佳聚类数量（图4）。结果显示，当聚类数超过5时，距离平方和下降速率显著降低，故选择聚类数 $k=5$ 作为最优解。




图 4: 肘部法则图

基于此，我们对孕妇平均BMI与Y染色体浓度进行了K-means聚类分析，结果如图5，图6所示。聚类结果清晰地展示了不同BMI区间与Y染色体浓度的关联模式。




图 5: 聚类结果柱状图图




图 6: 聚类结果散点图

6.3 聚类分类评价

为进一步评估聚类质量，我们计算了三个内部评价指标：

1.轮廓系数：0.551（轮廓系数取值范围[-1,1]，值越大表示同类样本越相近，不同类样本越远离，一般不可能大于0.7）

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \quad (4)$$

$a(i)$: 样本 i 到同一簇内所有其他样本的平均距离。（凝聚度） $b(i)$: 样本 i 到其他某个簇的所有样本的平均距离。计算样本 i 与所有非本身所在簇的的平均距离，然后取其中的最小值。（分离度）

2.DBI指数：0.517（值越小表示类内紧密度越高，类间分离度越好， ≤ 0.7 可接受）

$$DBI = \frac{1}{K} \sum_{i=1}^K \max_{j \neq i} R_{ij} \quad (5)$$

K : 簇的个数。 R_{ij} : 簇 i 和簇 j 之间的相似度 s_i : 簇 i 的簇内散度，即簇内所有样本到其质心 c_i 的平均距离。 d_{ij} : 簇 i 的质心 c_i 与簇 j 的质心 c_j 之间的距离（通常使用欧氏距离）。

3.CH指数：701.814（值越大表示聚类效果越优）

$$CH = \frac{SS_B / (K - 1)}{SS_W / (N - K)} \quad (6)$$

N : 数据集中的总样本数。 K : 簇的个数。 SS_B : 簇间离散度（Between-Cluster Sum of Squares）。所有簇的质心 c_k 与全局质心 c 的距离平方和，并按簇大小加权。 SS_W : 簇内离散度（Within-Cluster Sum of Squares）。所有样本点到其所属簇的质心的距离平方和。

上述指标综合表明，本次聚类效果良好，各类别内部样本相似度高，类别之间差异明显，分类结果可靠有效，为后续分析奠定了坚实基础。

6.4 NIPT时点计算

6.4.1 方法原理与模型构建

为确定各BMI分组的最佳NIPT检测时点，本研究构建了一个基于风险-效用权衡的优化模型。该模型综合考虑了早期检测与晚期检测的双重风险，通过数学优化方法寻找使总体风险最小化的检测时间点。

1. 风险函数定义：

- 早期检测风险(R_{early})：检测时间过早可能导致Y染色体浓度尚未达标，造成假阴性结果。我们采用指数衰减函数模拟这一风险：

$$R_{early}(t) = 2.0 \cdot e^{-t/50} \quad (7)$$

该函数从初始值2.0开始，随孕期增加呈指数衰减，反映早期预测的高风险性。

- 晚期检测风险(R_{late})：检测时间过晚则可能错过最佳干预时机。我们采用分段函数描述这一风险：

$$R_{late}(t) = \begin{cases} 0.1 & t < 84 \\ 0.1 + 0.9 \cdot \left(\frac{t-84}{189-84}\right)^2 & 84 \leq t \leq 189 \\ 1.0 & t > 189 \end{cases} \quad (8)$$

该函数在84天前保持低风险(0.1)，84-189天间以二次函数形式增长，189天后达到最高风险(1.0)。

2. 效用函数构建：

基于累积达标概率 $F(t)$ （通过Kaplan-Meier估计器计算）和上述风险函数，我们构建综合效用函数：

$$U(t) = (1 - F(t)) \cdot R_{early}(t) + F(t) \cdot R_{late}(t) \quad (9)$$

其中 $F(t)$ 表示在时间 t 之前Y染色体浓度达到4%的累积概率。

3. 优化目标：

通过最小化效用函数 $U(t)$ 确定最佳检测时点：

$$t^* = \arg \min_{t \in [0, T_{max}]} U(t) \quad (10)$$

其中 T_{max} 为观察期上限。

6.4.2 计算流程与实施

本研究采用以下步骤计算各BMI分组的最佳NIPT时点：

- 数据准备与分组：**基于聚类分析得到的5个BMI区间，将样本分为相应组别。
- 生存分析：**对每个BMI分组，应用Kaplan-Meier方法估计累积达标函数 $F(t)$ ，处理右删失数据（始终达标组和从不达标组）。
- 效用函数计算：**在时间域 $[0, T_{max}]$ 上离散采样，计算各时间点的效用值 $U(t)$ 。
- 优化求解：**采用有界优化算法（Bounded方法）寻找使 $U(t)$ 最小化的时间点 t^* 。
- 误差分析：**通过蒙特卡洛模拟（100次重复）评估检测误差对最优时点稳定性的影响。

6.4.3 结果与分析


表2展示了各BMI分组的最佳NIPT时点及相应指标：

表 2: 各BMI分组最佳NIPT时点计算结果

BMI分组	最优时点（天）	最小效用值	风险水平	样本量
<30.26	89.5	0.1299	7.696559	59
30.26-32.30	90.8	0.1360	7.3511	68
32.30-34.92	90.8	0.1359	7.3591	69
34.92-39.49	99.4	0.1569	6.3753	33
>39.49	110.7	0.1884	5.3090	4

结果表明，随着BMI增加，最佳检测时点相应延后，而效用值逐渐增加（风险水平降低）。这一趋势与临床观察一致，高BMI孕妇需要更长时间等待Y染色体浓度达标，但一旦达标，其检测风险相对较低。

图3展示了分类中一组的典型分析结果，包括累积达标曲线、效用函数曲线及最优时点标注。（剩余的会在附录中给出）



6.4.4 误差敏感性分析

为评估检测误差对结果稳定性的影响，我们进行了蒙特卡洛模拟分析。假设检测误差服从正态分布（标准差= 5%），对每个BMI分组进行100次重复模拟。

表3和表4展示了误差分析结果： 结果表明：

1. 检测误差对最优时点的影响较小（时点变异系数 $\leq 3.5\%$ ），模型具有较好的稳健性。
2. 高BMI分组对检测误差更为敏感，时点波动范围更大。
3. 所有分组的95%置信区间范围合理，验证了推荐时点的可靠性。

表 3: 检测误差对最优时点的影响分析（时点相关指标）

BMI分组	原始最优时点（天）	模拟最优时点均值（天）	时点标准差（天）	95%置信区间（天）
<30.26	89.51	90.05	1.56	(89.74, 90.35)
30.26-32.30	90.79	92.64	2.52	(92.14, 93.13)
32.30-34.92	90.76	91.19	1.39	(90.92, 91.46)
34.92-39.49	99.44	100.04	2.37	(99.58, 100.51)
>39.49	110.75	110.11	3.49	(109.43, 110.79)

表 4: 检测误差对最优时点的影响分析（效用值与风险水平相关指标）

BMI分组	原始最小效用值	模拟最小效用值均值	效用值标准差	原始风险水平	模拟风险水平均值	风险水平标准差
<30.26	0.1299	0.1274	0.0023	7.6965	7.8546	0.1448
30.26-32.30	0.1360	0.1322	0.0032	7.3511	7.5677	0.1808
32.30-34.92	0.1359	0.1336	0.0021	7.3591	7.4851	0.1199
34.92-39.49	0.1569	0.1594	0.0027	6.3753	6.2773	0.1072
>39.49	0.1884	0.1829	0.0124	5.3090	5.4973	0.4362

4. 效用值和风险水平的变异程度相对较小，表明模型对这些指标的预测较为稳定。

图4展示了其中一组的误差模拟的详细结果，包括时点分布、效用值分布及风险分布。（其余的会在附录中给出）




图 8: 32.30-34.92组

6.4.5 创新与亮点

本研究在NIPT时点计算方面具有以下创新点：

1.综合风险建模：首次将早期检测风险与晚期检测风险同时纳入考量，构建了更符合临床实际的

效用函数。

2.生存分析方法应用：采用Kaplan-Meier方法处理右删失数据，提高了累积达标概率估计的准确性。

3.蒙特卡洛误差分析：通过模拟检测误差的影响，量化了模型的稳健性，为临床决策提供了可靠性评估。

4.BMI分层优化：针对不同BMI群体分别计算最优时点，实现了个性化检测推荐。

本研究提供的NIPT时点推荐方案，不仅考虑了检测准确性，还综合评估了时间相关的风险因素，为临床实践提供了科学依据。结果表明，基于BMI分层的个性化检测时点选择，能够有效降低孕妇的潜在风险，提高检测效率。

七 问题三模型建立求解

7.1 数据预处理

本问题旨在综合考虑身高、体重、年龄、检测误差和胎儿的 Y 染色体浓度达标比例（即浓度达到或超过 4%的比例），根据男胎孕妇的 BMI，给出合理分组以及每组的最佳 NIPT 时点，使得孕妇潜在风险最小，并分析检测误差对结果的影响。

为合理区分样本并便于计算NIPT最佳时点，我们依据Y染色体浓度达标情况对孕妇分为三组：**始终达标组、中间达标组与从不达标组**(分组方法与第二组类似)。我们同样剔除掉了曾达标但后续检测又低于4%的样本以确保数据质量。最终获得有效样本总量为 230例。其中，第一组186例（占比80.87%），第二组37例（占比16.09%），第三组7例（占比 3.04%）。

和问题二不同的是，该问中同一孕妇BMI和体重并没有求平均值，而是保留了每一项原数据，这主要是因为第二问需要综合考虑更多干扰因素：样本中有相当一部分的人体重变化比较明显，直接求平均值会丢失体重和BMI增长的信息，与题目关注干扰项的思想不符。反观第二题，研究重心主要放在探究NITP时点上，其他干扰因素全都暂不考虑，BMI也更多只是起分类作用，所以才可以直接求平均值。

此外由于人的BMI在短时间内变化幅度较小，不便于观测计算。我们便对每一位孕妇的BMI进行了Z标准化，这也为我们之后进行多变量聚类分析打下了基础。

公式如下

$$Z = \frac{X - \mu}{\sigma} \quad (7)$$

其中 X 为待检测样本中目标染色体的相对计数比例， μ 为正常对照群体中该染色体计数比例的均值， σ 为正常群体中该比例的标准差。在NIPT中，对于常见染色体非整倍体检测，通常采用Z值分析方法进行统计判定。

7.2 聚类分析与BMI划分

为科学划分孕妇群体并识别BMI与Y染色体浓度达标模式之间的关系，我们采用两种聚类方法进行比较分析。

7.2.1 多参数聚类分析

首先基于身高、体重、年龄等多维特征进行聚类。利用肘部法则确定最佳聚类数，可见当聚类数 $k=10$ 时，类内距离平方和下降速率显著趋缓，故聚类数目定为10。




图 9: 肘部法则图

完成聚类后，生成聚类散点图（图10），从中可初步观察不同类别在特征空间中的分布及其所反映的群体结构。




图 10: （多参数）聚类结果散点图

此外我们得到该聚类模型的性能指标如下：

- 轮廓系数 (Silhouette Score): 0.275
- DBI指数 (Davies-Bouldin Index): 1.06
- CH指数 (Calinski-Harabasz Index): 295.864

这些指标表明，多参数聚类虽然能够实现基本分类，但聚类效果一般。轮廓系数较低表明类间分离度不够理想，而较高的DBI指数也提示类内紧密性和类间分离度的平衡有待提升。

7.2.2 天数与BMI的聚类分析

针对NIPT检测时点选择问题的特点，我们进一步采用了以检测天数和BMI为核心特征的聚类方法。同样通过肘部法则确定最佳聚类数为5类，散点图显示各类别在天数-BMI特征空间中分布更为清晰，重叠较少。




图 11: (BMI对y染色体浓度) 肘部法则图

聚类结果如图12所示，散点图清晰展示了5个聚类簇的分布，不同簇对应了BMI与Y染色体浓度的典型组合模式，为后续分组制定最佳检测时点提供了依据。





图 12: (BMI对y染色体浓度) 聚类结果散点图

此外我们得到该聚类模型的性能指标显著优于多参数聚类：

- 轮廓系数 (Silhouette Score): 0.5406
- DBI指数 (Davies-Bouldin Index): 0.5487
- CH指数 (Calinski-Harabasz Index): 2555.3896

更重要的是，该方法产生了具有明确临床意义的BMI区间划分

- 聚类 0: BMI范围: 34.63-37.64 (肥胖)
- 聚类 1: BMI范围: 30.02-32.17 (肥胖)
- 聚类 2: BMI范围: 26.62-30.00 (肥胖)
- 聚类 3: BMI范围: 32.19-34.62 (肥胖)
- 聚类 4: BMI范围: 38.22-45.71 (肥胖)

7.2.3 聚类方法对比分析

通过对比两种聚类方法的性能指标并结合实际应用需求，可以发现天数-BMI聚类方法相比多参数聚类具有明显优势，具体体现在以下四个方面：

首先，从聚类质量来看，天数-BMI聚类的轮廓系数达到0.5406，明显高于多参数聚类的0.275，说明各类别之间的区分度更高，内部样本更加紧密。同时，其DBI指数仅为0.5487，远低于多参数聚类的1.06，进一步验证了该方法在保持类内紧密性的同时实现了更好的类间分离效果。

其次，就聚类结构的稳定性而言，天数-BMI聚类的CH指数达到2555.3896，是多参数聚类的8倍以上，这一结果明确显示其生成的类别结构更加清晰和稳定。

第三，从临床应用的视角来看，天数-BMI聚类得出的BMI区间划分具有明确的临床意义，与肥胖程度的分级标准相吻合，便于在实际检测中进行风险评估和时点选择。

最后，该方法在特征选择方面更具针对性，聚焦于与NIPT检测时点直接相关的天数和BMI特征，避免了其他无关特征的干扰，提高了聚类结果的实用价值。

基于上述分析，本研究最终选择天数-BMI聚类方法作为分组依据。

7.3 建模方法分析不同BMI分组中年龄、身高、体重对NIPT最佳时点的影响

7.3.1 整体建模框架

本研究采用多阶段建模框架，旨在系统分析各BMI分组中年龄、身高、体重对Y染色体浓度达标时间（即NIPT最佳时点）的影响。整体流程如下：

1.生存分析建模：基于Kaplan-Meier估计器构建累积达标函数，刻画Y染色体浓度随时间达到4%的累积概率；

2.效用-风险权衡：引入早期检测效用函数与晚期检测风险函数，构建总效用函数，以量化不同检测时点的综合收益；

3.最优时点求解：通过最小化总效用函数，确定各BMI分组下的最优NIPT检测时点；

4.影响因素建模：基于随机森林（大样本）或线性回归（小样本）模型，量化年龄、身高、体重对达标时间的影响强度；

5.模型验证与解释：通过交叉验证、SHAP值分析等方法评估模型性能并解释特征影响。

7.3.2 生存分析与效用理论

1.Kaplan-Meier累积达标函数

设 T 为Y染色体浓度首次达到4%的时间（单位：天）， $F(t)$ 表示时间 t 前达标的累积概率，则生存函数 $S(t) = P(T > t) = 1 - F(t)$ 。基于Kaplan-Meier估计器：

$$S(t) = \prod_{i:t_i \leq t} \left(1 - \frac{d_i}{n_i}\right) \quad (11)$$

其中 d_i 为 t_i 时刻达标事件数， n_i 为风险集大小。

2.效用函数设计

- 早期检测效用函数（指数衰减）：

$$U_{\text{early}}(t) = 2.0 \cdot \exp\left(-\frac{t}{50}\right) \quad (12)$$

- 晚期检测风险函数（分段定义）：

$$R_{\text{late}}(t) = \begin{cases} 0.1 & t < 84 \\ 0.1 + 0.9 \left(\frac{t-84}{105}\right)^2 & 84 \leq t \leq 189 \\ 1.0 & t > 189 \end{cases} \quad (13)$$

- 总效用函数（期望效用）：

$$E[U(t)] = S(t) \cdot U_{\text{early}}(t) + [1 - S(t)] \cdot R_{\text{late}}(t) \quad (14)$$

3.最优时点求解 通过最小化总效用函数得到最优时点 t^* ：

$$t^* = \arg \min_{t \geq 0} E[U(t)] \quad (15)$$

使用‘`scipy.optimize.minimize_scalar`’方法在有界区间内求解。

7.3.3 影响因素建模方法

1.随机森林回归（适用于大样本分组）

对于样本量 ≥ 10 的分组（聚类0-3），采用随机森林回归模型建模达标时间 T 与特征 $X = (\text{年龄}, \text{身高}, \text{体重})$ 的关系：

$$T = f(X) + \epsilon \quad (16)$$

其中 $f(\cdot)$ 为随机森林模型，通过Bootstrap聚合多棵决策树提升预测鲁棒性。具体而言，随机森林通过以下方式构建：

1. 从原始数据集中有放回地抽取 B 个Bootstrap样本（本研究中 $B = 100$ ）；
2. 对每个Bootstrap样本构建决策树，且在每次分裂时随机选择 m 个特征（通常 $m = \sqrt{p}$ ， p 为特征总数）进行评估；
3. 最终预测值为所有决策树预测的平均值：

$$\hat{f}(X) = \frac{1}{B} \sum_{b=1}^B T_b(X) \quad (17)$$

特征重要性计算：通过Gini不纯度减少量或平均精度下降（Mean Decrease Accuracy）评估特征重要性。对于特征 j ，其重要性可计算为：

$$\text{Importance}(j) = \frac{1}{B} \sum_{b=1}^B \sum_{t \in T_b} \Delta \text{Gini}(t, j) \quad (18)$$

其中 $\Delta \text{Gini}(t, j)$ 表示在树 T_b 的节点 t 上使用特征 j 分裂带来的Gini不纯度减少量。

交叉验证：采用5折交叉验证评估模型性能，计算 R^2 与平均绝对误差（MAE）：

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (19)$$

2.SHAP值分析原理与计算

SHAP（SHapley Additive exPlanations）值基于合作博弈论中的Shapley值理论，为每个特征分配一个特定预测中的贡献值，提供模型预测的局部可解释性。

Shapley值定义：对于特征 j 在样本 x 上的SHAP值 ϕ_j 计算如下：

$$\phi_j = \sum_{S \subseteq F \setminus \{j\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [f(S \cup \{j\}) - f(S)] \quad (20)$$

其中：

- F 为所有特征的集合；
- S 为不包括特征 j 的特征子集；
- $f(S)$ 表示仅使用特征子集 S 时的模型预测值；
- $f(S \cup \{j\})$ 表示加入特征 j 后的模型预测值。

实际计算中的近似：精确计算SHAP值是指数级的，对于树模型采用TreeSHAP算法高效计算：

$$\phi_j = \frac{1}{B} \sum_{b=1}^B \phi_j^b \quad (21)$$

其中 ϕ_j^b 表示在第 b 棵树上的SHAP值，通过递归遍历决策树计算：

$$\phi_j^b = \sum_{t=1}^{T_b} \phi_{j,t}^b = \sum_{t=1}^{T_b} \frac{\text{cover}(t)}{\text{cover}(\text{parent}(t))} (v_t - v_{\text{parent}(t)}) \quad (22)$$

其中：

- T_b 为树 b 的节点总数；
- $\text{cover}(t)$ 表示节点 t 的样本覆盖数；
- v_t 表示节点 t 的输出值；
- $v_{\text{parent}(t)}$ 表示父节点的输出值。

SHAP值优良的性质：

1. 局部准确性：模型预测值可表示为基准预测与各特征SHAP值之和：

$$f(x) = \phi_0 + \sum_{j=1}^p \phi_j \quad (23)$$

其中 ϕ_0 为基准值（通常为训练集预测均值）。

2. 一致性：若模型更改使得某个特征的贡献增加，则该特征的SHAP值也应增加。

本研究使用Python的SHAP库计算TreeExplainer，生成特征贡献的可视化分析，包括：

- **SHAP摘要图**：显示各特征SHAP值的分布及与特征值的关系；
- **特征依赖图**：展示单一特征与SHAP值之间的非线性关系；
- **力力图**：个体样本预测的局部解释，显示各特征对特定预测的贡献方向与大小。

3.线性回归（适用于小样本分组）

对于样本量<10的分组（聚类4），采用多元线性回归：

$$T = \beta_0 + \beta_1 \cdot \text{年龄} + \beta_2 \cdot \text{身高} + \beta_3 \cdot \text{体重} + \epsilon \quad (24)$$

特征重要性通过标准化系数绝对值占比计算：

$$\text{Importance}(j) = \frac{|\beta_j \cdot \sigma_j|}{\sum_{k=1}^p |\beta_k \cdot \sigma_k|} \quad (25)$$

其中 σ_j 为特征 j 的标准差。

通过SHAP值分析，本研究不仅提供了特征重要性的全局视角，还揭示了个体预测中特征的贡献模式，增强了模型的可解释性和临床实用性。

7.3.4 各BMI分组建模结果分析

下表系统总结了各BMI分组的建模结果，包括最优NIPT时点、效用-风险指标、样本量、特征重要性分布及模型性能：**表注与说明：**

BMI分组	聚类1 (30.01-32.18)	聚类1 (30.01-32.18)	聚类2 (32.18-34.63)	聚类3 (34.63-37.93)	聚类4 (≥ 37.93)
最优时点(天)	96.5	97.6	97.5	99.4	103.7
最优时点(周)	13.8	13.9	13.9	14.2	14.8
最小效用值	0.1373	0.1299	0.1260	0.1475	0.1659
风险水平	7.2813	7.6957	7.9363	6.7795	6.0288
样本量	65	68	61	22	7
年龄重要性	23.84%	22.43%	26.47%	10.56%	6.00%
身高重要性	24.86%	34.74%	28.17%	28.82%	43.24%
体重重要性	51.30%	42.83%	45.37%	60.62%	50.77%
模型 R^2	-0.8187	-1.0528	-0.3296	-2.9426	0.8433
模型MAE(天)	5.17	3.08	2.45	5.21	8.67
改进百分比(%)	46.09	60.49	58.19	65.79	56.02

表 5: 建模结果表格

1.特征重要性: 采用随机森林（聚类0-3）或线性回归系数归一化（聚类4）计算，反映了各变量对达标时间影响的相对强度；

2.模型性能:

- R^2 得分: 随机森林模型出现负值表明模型性能优于简单均值预测，线性回归模型 $R^2=0.8433$ 表明良好拟合；
- MAE改进百分比: 计算公式为 $\frac{\text{基准MAE}-\text{模型MAE}}{\text{基准MAE}} \times 100\%$ ，基准为仅使用均值预测的MAE；

3.效用-风险指标: 最小效用值越低表示该时点综合收益越高，风险水平为效用值的倒数；

4.样本量: 聚类4样本量较小（ $n=7$ ），结果解释需谨慎。

7.3.5 关键发现与讨论

1.BMI与最优时点正相关: 随着BMI分组升高，最优时点从96.5天（聚类0）延迟至103.7天（聚类4），符合临床观察中肥胖孕妇需推迟检测的共识。

2.体重为主导因素: 在所有分组中，体重对达标时间的影响最大（重要性占比50.8–60.6%），表明体液稀释效应对Y染色体浓度检测影响显著。

3.身高与年龄的异质性影响: - 身高在聚类1、4中影响显著，可能与体型分布有关； - 年龄在聚类0–2中影响较明显，但在高BMI组中影响减弱。**4.模型选择的有效性:** 随机森林在多数分组中表现优异（提升46.1–65.8%），线性回归在小样本情况下仍能提供可靠预测。

5.SHAP值增强可解释性: 通过可视化各特征贡献方向与程度，为临床决策提供直观依据。

7.4 误差分析

7.4.1 分析方法与原理

为评估Y染色体浓度检测误差对NIPT最佳时点推荐稳定性的影响，本研究采用**蒙特卡洛模拟**方法进行误差敏感性分析。该方法通过多次重复模拟实验，量化随机误差对模型输出的影响程度，为临床决策提供可靠性评估。

误差模型构建:

假设检测误差服从均值为0、标准差为 σ 的正态分布:

$$\epsilon \sim N(0, \epsilon^2), \epsilon = 0.01$$

带误差的Y染色体浓度测量值为： $c_{error}=c_{true}+\epsilon_{error}=c_{true}+\epsilon$ 模拟流程：

1. 对原始数据中的Y染色体浓度添加随机误差，生成100组扰动数据集
2. 对每个扰动数据集重新计算达标时间（采用线性插值法）
3. 基于新的达标时间数据重构Kaplan-Meier生存曲线
4. 重新优化计算最优时点、最小效用值和风险水平
5. 统计分析100次模拟结果的分布特征

统计指标：

- 均值： $\mu = \frac{1}{n} \sum_{i=1}^n x_i$
- 标准差： $\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2}$
- 95%置信区间： $\mu \pm 1.96 \cdot \frac{\sigma}{\sqrt{n}}$

7.4.2 误差分析结果

表3-4展示了各BMI分组在检测误差影响下的稳定性分析结果：

表 6: 表3-4：检测误差对NIPT时点推荐的影响分析

BMI分组	指标类型	原始值	模拟均值	标准差	95%置信区间	变异系数(%)
聚类0 (≤30.01)	最优时点(天)	96.50	97.72	1.53	(97.42, 98.02)	1.57
	最小效用值	0.1373	0.1385	0.0043	(0.1377, 0.1393)	3.10
	风险水平	7.2813	7.2256	0.2231	(7.1821, 7.2691)	3.09
聚类1 (30.01-32.18)	最优时点(天)	97.56	98.11	1.68	(97.78, 98.44)	1.71
	最小效用值	0.1299	0.1329	0.0044	(0.1320, 0.1338)	3.31
	风险水平	7.6957	7.5302	0.2481	(7.4816, 7.5788)	3.29
聚类2 (32.18-34.63)	最优时点(天)	97.50	98.36	1.10	(98.14, 98.58)	1.12
	最小效用值	0.1260	0.1255	0.0033	(0.1249, 0.1261)	2.63
	风险水平	7.9363	7.9762	0.2080	(7.9354, 8.0170)	2.61
聚类3 (34.63-37.93)	最优时点(天)	99.44	99.05	3.53	(98.36, 99.74)	3.56
	最小效用值	0.1475	0.1452	0.0080	(0.1437, 0.1467)	5.51
	风险水平	6.7795	6.9077	0.3863	(6.8321, 6.9833)	5.59
聚类4 (≥37.93)	最优时点(天)	103.69	102.744.59	(101.84, 103.64)	4.47	
	最小效用值	0.1659	0.1660	0.0138	(0.1633, 0.1687)	8.31
	风险水平	6.0288	6.0700	0.5411	(5.9640, 6.1760)	8.91

7.4.3 结果讨论与临床意义

1.时点稳定性分析：

- 所有BMI分组的时点变异系数均低于5%，表明模型具有较强的抗干扰能力
- 聚类4(高BMI组)的时点波动最大(4.47%)，这与样本量较小(n=7)有关
- 95%置信区间范围合理，验证了推荐时点的可靠性

2.效用值与风险水平稳定性：

- 低BMI分组(聚类0-2)的效用值变异系数≤3.5%，表现稳定
- 高BMI分组(聚类3-4)的变异系数较高(5.51-8.91%)，建议临床应用中适当放宽时间窗口

3.误差传播规律：

- 检测误差对最优时点的影响呈正相关：误差越大，时点推荐波动越大
- 高BMI群体对检测误差更为敏感，这与其达标时间较晚、数据点稀疏有关
- 效用函数的设计有效平抑了误差影响，体现了模型良好的鲁棒性

4.临床建议：

- 对于低BMI群体(聚类0-2)，可严格遵循推荐时点(97-98天)进行检测
- 对于高BMI群体(聚类3-4)，建议采用时间窗口而非单一时点(如聚类4：102±5天)
- 在检测设备精度有限的情况下，可适当延长检测时间以抵消误差影响

本研究通过严格的误差敏感性分析证实了推荐时点的可靠性。结果表明，在常规检测误差范围内($\sigma=0.01$)，模型推荐时点的波动小于5天，具有较好的临床适用性。

八 问题四模型建立求解

8.1 数据预处理

本研究旨在建立女胎染色体非整倍体（21三体、18三体和13三体）的异常判定模型。首先对原始数据进行了严格的质控筛选：对BMI缺失值使用群体平均值进行填补；依据GC含量的正常生物学范围（40%-60%）和X染色体Z值的合理区间（-3至3），剔除了不符合质控标准的样本，确保了后续分析数据的高质量和可靠性。

8.2 编码

为将分类目标转换为模型可处理的形式，对“身体没有异常”、“T21”、“T18”、“T13”这4种临床结局采用独热编码（One-Hot Encoding），生成对应的二分类变量。在建模时仅使用后三个异常标签作为目标，以避免多重共线性问题。此外，由于各特征变量的量纲和数量级差异显著，对所有连续型特征进行了Z-score 标准化处理，以消除量纲对模型的影响。

8.3 特征筛选

鉴于目标变量为二分类变量而特征均为连续变量，采用点二列相关系数（Point-Biserial Correlation）定量评估每个特征与分类目标之间的相关性。其计算公式如下：

$$r_{pb} = \frac{M_1 - M_0}{S_t} \cdot \sqrt{p \cdot q} \quad (8)$$

r_{pb} ：点二列相关系数； M_1 ：连续变量中，与二分变量某一类别（通常记为“1”）对应的均值（如“通过考试”组的成绩均值）； M_0 ：连续变量中，与二分变量另一类别（通常记为“0”）对应的均值（如“未通过考试”组的成绩均值）； S_t ：连续变量的总标准差（所有数据的标准差）； p ：二分变量中“1”类别的比例（如通过考试的人数占总人数的比例）； q ：二分变量中“0”类别的比例（ $q = 1 - p$ ）。

计算所有特征的相关系数绝对值后，筛选出最重要的15个特征用于后续建模下图，有效去除了不相关或冗余特征，降低了模型复杂度。




图 13: 特诊与点二列相关系数绝对值

8.4 采样方法

由于我们的数据有明显的样本不均衡（患病样本远小于健康样本），因此我们决定使用**SMOTEENN** (**SMOTE** + **Edited Nearest Neighbors**) 采样方法，

解读 **SMOTEENN** 采样后的模型评估结果

8.4.1 数据分布变化

原始数据中正常样本（0类）有486个，异常样本（1类）有58个，故异常比例 为 $58/(486+58) \approx 10.7\%$ ，存在严重的类别不平衡问题。

为克服由此导致的模型偏见，采用**SMOTEENN**混合采样算法，该算法结合了**SMOTE**过采样和**ENN**欠采样：通过合成少数类样本增加其数量，同时清理多数类样本中与近邻类别不一致的样本。而在经过**SMOTEENN**处理后，正常样本（0类）有185个，异常样本（1类）有215个。异常比例为 $215/(215+185) \approx 53.8\%$ （变为平衡数据）这其中的**关键变化**是异常样本数量从58 → 215（增加257%），正常样本数量从486 → 185（减少62%），实现了类别平衡，为构建高性能的分类器奠定了数据基础。

8.4.2 模型性能评估（随机森林）

其中的核心指标如下：

可以看到效果较好

指标	值	医疗诊断意义
准确率	0.9250	整体预测正确率92.5%
精确率	0.9104	诊断为”异常”的病例中，91.04%是真正的异常
召回率	0.9531	能检测出95.31%的真实异常病例
F1分数	0.9313	综合性能优秀（接近1为最佳）
AUC	0.9676	模型区分能力极强（≥0.9即为优秀）

表 7: 农作物相关数据（美观版）

8.5 建立模型

8.5.1 模型选择

为寻找最优判定方法，系统比较了随机森林（Random Forest）、XGBoost和支持向量机（SVM）三种主流模型。




图 14: 不同模型的性能比较




图 15: 精准率-召回率曲线比较

如图所示，从整体性能指标和精确率-召回率曲线（PR Curve）综合来看，随机森林在各项评估中均表现最佳，尤其在捕捉正例（异常）方面展现出卓越的稳健性和泛化能力，因此被选定为最终建模算法。

8.5.2 算法原理与实现

随机森林通过Bootstrap抽样从原始训练集中生成多个子样本集，针对每个子样本集构建决策树。在树的生成过程中，节点分裂时从全部特征中随机选取部分特征作为候选特征，进一步增强模型的多样性。最终通过投票或平均方式集成所有树的预测结果。

本研究基于Scikit-learn库实现随机森林分类器，并采用交叉验证与网格搜索方法进行超参数调优，以确定最佳参数组合。

8.5.3 超参数调优与交叉验证

通过网格搜索（Grid Search）方法对随机森林的关键超参数进行调优，包括决策树数量（`n_estimators`）、最大树深度（`max_depth`）、最小分裂样本数（`min_samples_split`）和最小叶节点样本数（`min_samples_leaf`）。采用5折交叉验证评估每组参数的性能，最终确定最优参数组合为：

- 决策树数量（`n_estimators`）：100
- 最小分裂样本数（`min_samples_split`）：5
- 最小叶节点样本数（`min_samples_leaf`）：1

- 最大树深度 (max_depth): 无限制

该参数组合在交叉验证中取得了最佳性能，交叉验证准确率达到0.8987。

8.5.4 模型性能评估

使用调优后的参数训练最终模型，并在测试集上评估其性能，结果如下：

- 测试集准确率：0.8917
- 测试集精确率：0.9048
- 测试集召回率：0.8906
- 测试集AUC：0.9570
- 测试集F1分数：0.8976

进一步对最终模型进行交叉验证评估，结果显示：

- 交叉验证准确率：0.9225 (± 0.0166)
- 交叉验证F1分数：0.9300 (± 0.0148)
- 交叉验证AUC：0.9734 (± 0.0140)
- 交叉验证精确率：0.9040 (± 0.0201)
- 交叉验证召回率：0.9581 (± 0.0228)

最终模型的详细评估结果如下：

	precision	recall	f1-score	support
0	0.94	0.89	0.92	56
1	0.91	0.95	0.93	64
accuracy			0.93	120
macro avg	0.93	0.92	0.92	120
weighted avg	0.93	0.93	0.92	120
...	...	...		

表 8: 评估结果

模型整体准确率达到0.9250，精确率为0.9104，召回率为0.9531，AUC为0.9676，F1分数为0.9313。这些结果表明，经过超参数调优的随机森林模型在各项指标上均表现出色，具有较高的分类准确性和良好的泛化能力，能够有效应用于后续的分类任务。

8.6 特征重要性分析与模型可解释性

为深入理解模型的决策机制并增强其可解释性，我们进一步分析了随机森林模型所学习到的特征重要性。（如下图）该分析揭示了影响女胎染色体异常判定的最关键因素，其排序与临床先验知识高度一致，有力地证明了模型的可信度与生物学合理性。

分析结果表明，唯一比对的读段数是重要性最高的特征，它直接代表了测序数据的有效深度与质量，是后续所有分析可靠性的根本保障。紧随其后的核心预测因子是21号、18号和13号染色体的Z值，这些指标是产前筛查中判断染色体非整倍体的直接生物标志物，其重要性排名靠前符合临床预期。此外，X染色体的Z值、各类GC含量指标以及其他测序质量相关特征（如重复读段比例）也贡献了显著的预测价值，它们从不同维度反映了样本的质量和潜在的系统偏差。




图 16: 以下是random_forest 超参数调优后 ROC曲线

8.7 结论

本研究成功构建了一个基于随机森林的女胎染色体异常判定模型。该模型仅需输入15项临床与测序指标：

- 1.基本信息：** 孕妇年龄, 孕妇BMI, 怀孕次数, 生产次数
- 2.Z值：** X染色体的Z值, 13号染色体的Z值, 18号染色体的Z值, 21号染色体的Z值
- 3.GC相关：** GC含量, 13号染色体的GC含量, 18号染色体的GC含量, 21号染色体的GC含量
- 4.测序质量：** 原始读段数, 唯一比对的读段数, 重复读段的比例

即可高效、准确地计算出胎儿罹患T21、T18或T13的风险概率，为临床无创产前筛查提供了强有力的数据驱动辅助工具。

九 参考文献

- [1] Scientific Platform Serving for Statistics Professional 2021. SPSSPRO. (Version 1.0.11)[Online Application Software]. Retrieved from <https://www.spsspro.com>.
- [2] Saroj,Kavita.Review:study on simple k mean and modified K mean clustering technique[J].International Journal of Computer Science Engineering and Technology,2016,6(7): 279-281.
- [3] Kaplan, E. L.; Meier, P. (1958). "Nonparametric estimation from incomplete observations". Journal of the American Statistical Association. 53 (282): 457–481.
- [4] Virtanen, P. et al. (2020). "SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python". Nature Methods. 17: 261–272.
- [5] Davidson-Pilon, C. (2019). "Lifelines: Survival Analysis in Python". Journal of Open Source Software. 4(40): 1317.

十一 附录

附录 1: 支撑材料, 文件列表附录 2: 补充表格, 图片附录 3: 代码

附录 1: 支撑材料文件列表

- 问题一 • 混合模型 (R 语言代码)
- 问题二 • C(2)(权重计算).py
- C(2)(生存函数).py
 - C(2)(正态分布检验).py
 - C(2) 测试误差.py
 - C(2)(权重计算).py
 - C(2) 聚类.py
 - 不同组的累积达标曲线、效用函数曲线及最优时点标注图
 - 不同组的误差模拟 (时点分布、效用值分布及风险分布) 图
- 问题三 • 模拟退火算法
- 问题四 • 打折统计图
- 蔬菜品类销售量灰色关联分析
 - 退货统计图

附录 2: 补充表格, 图片




图 1: 累积达标曲线 (小于 30.26 组)




图 2: 累积达标曲线 (30.26-32.30 组)




图 3: 累积达标曲线 (34.92-39.49 组)




图 4: 累积达标曲线（大于 39.49 组）




图 5: 误差模拟（小于 30.26 组）




图 6: 误差模拟 (30.26-32.30 组)




图 7: 误差模拟 (34.92-39.49 组)




图 8: 误差模拟 (大于 39.49 组)

Listing 1: 混合模型.py

```

1  # 加载必要的包
2  library(readxl)
3  library(nlme)
4  library(ggplot2)
5  library(lme4)
6  library(MuMIn)
7  library(mgcv) # 用于GAMM模型
8  library(merTools)
9  library(sjPlot)
10 library(gridExtra)
11 library(itsadug) # 用于GAM模型可视化
12
13 # 读取数据
14 data_path <- "D:/math_modeling/25_C/mathmodeling_2024(1)/文件/副本C(1)_total.xlsx"
15 data <- read_excel(data_path)
16
17 # 查看数据结构
18 str(data)
19 head(data)
20
21 # 重命名列名以便使用
22 colnames(data) <- c("Subject", "BMI", "Y_concentration", "Gestational_days")
23
24 # 数据预处理
25 data$Subject <- as.factor(data$Subject)
26 data$BMI <- as.numeric(data$BMI)
27 data$Y_concentration <- as.numeric(data$Y_concentration)
28 data$Gestational_days <- as.numeric(data$Gestational_days)

```

```

29
30 # 探索性数据分析
31 exploratory_plot <- ggplot(data, aes(x = Gestational_days, y = Y_concentration, color = Subject)) +
32   geom_point() +
33   geom_smooth(method = "lm", se = FALSE) +
34   theme_minimal() +
35   labs(title = "Y染色体浓度随孕周变化", x = "孕周(天)", y = "Y染色体浓度")
36
37 print(exploratory_plot)
38 ggsave("exploratory_plot.png", width = 10, height = 6, dpi = 300)
39
40 # 1. 线性混合模型 (LMM)
41 cat("拟合线性混合模型...\n")
42 lmm_model <- lmer(Y_concentration ~ BMI + Gestational_days + (1|Subject), data = data)
43 cat("线性混合模型拟合完成\n")
44 print(summary(lmm_model))
45
46 # 2. 指数模型
47 cat("拟合指数模型...\n")
48 exp_model_formula <- function(bmi, days, a, b, c) {
49   a * exp(b * bmi + c * days)
50 }
51
52 tryCatch({
53   exp_nlme <- nlme(Y_concentration ~ exp_model_formula(BMI, Gestational_days, a, b, c),
54     data = data,
55     fixed = a + b + c ~ 1,
56     random = a ~ 1 | Subject,
57     start = list(a = 0.05, b = 0.001, c = 0.001),
58     control = nlmeControl(maxIter = 2000, pnlsTol = 1e-4, msTol = 1e-4))
59   cat("指数模型拟合成功\n")
60   print(summary(exp_nlme))
61 }, error = function(e) {
62   message("指数模型拟合失败: ", e$message)
63   exp_nlme <- NULL
64 })
65
66 # 3. Logistic生长模型
67 cat("拟合Logistic模型...\n")
68 logistic_model_formula <- function(bmi, days, a, b, c, d) {
69   a / (1 + exp(-(b * bmi + c * days - d)))
70 }
71
72 tryCatch({
73   logistic_nlme <- nlme(Y_concentration ~ logistic_model_formula(BMI, Gestational_days, a, b, c, d),
74     data = data,
75     fixed = a + b + c + d ~ 1,
76     random = a ~ 1 | Subject,
77     start = list(a = 0.1, b = 0.01, c = 0.01, d = 50),
78     control = nlmeControl(maxIter = 2000, pnlsTol = 1e-4, msTol = 1e-4))
79   cat("Logistic模型拟合成功\n")
80   print(summary(logistic_nlme))
81 }, error = function(e) {
82   message("Logistic模型拟合失败: ", e$message)
83   logistic_nlme <- NULL

```

```

84 })
85
86 # 4. Gompertz 生长模型
87 cat("拟合 Gompertz 模型...\n")
88 gompertz_model_formula <- function(bmi, days, a, b, c, d) {
89   a * exp(-exp(-(b * bmi + c * days - d)))
90 }
91
92 tryCatch({
93   gompertz_nlme <- nlme(Y_concentration ~ gompertz_model_formula(BMI, Gestational_days, a, b, c, d),
94     data = data,
95     fixed = a + b + c + d ~ 1,
96     random = a ~ 1 | Subject,
97     start = list(a = 0.1, b = 0.01, c = 0.01, d = 50),
98     control = nlmeControl(maxIter = 2000, pnlsTol = 1e-4, msTol = 1e-4))
99   cat("Gompertz 模型拟合成功\n")
100   print(summary(gompertz_nlme))
101 }, error = function(e) {
102   message("Gompertz 模型拟合失败: ", e$message)
103   gompertz_nlme <- NULL
104 })
105
106 # 5. 广义加性混合模型 (GAMM)
107 cat("拟合广义加性混合模型...\n")
108 tryCatch({
109   # 使用 bam 函数拟合 GAMM, 适用于大型数据集
110   gamm_model <- bam(Y_concentration ~ s(BMI) + s(Gestational_days) + s(Subject, bs = "re"),
111     data = data,
112     method = "REML")
113   cat("GAMM 模型拟合成功\n")
114   print(summary(gamm_model))
115
116   # 绘制平滑项图
117   png("gamm_smooth_terms.png", width = 10, height = 6, units = "in", res = 300)
118   par(mfrow = c(1, 2))
119   plot(gamm_model, select = 1, main = "BMI 平滑项")
120   plot(gamm_model, select = 2, main = "孕周平滑项")
121   dev.off()
122 }, error = function(e) {
123   message("GAMM 模型拟合失败: ", e$message)
124   gamm_model <- NULL
125 })
126
127 # 模型比较
128 cat("开始模型比较...\n")
129 model_comparison <- data.frame(
130   Model = "线性混合模型",
131   AIC = AIC(lmm_model),
132   BIC = BIC(lmm_model),
133   LogLik = as.numeric(logLik(lmm_model))
134 )
135
136 # 添加非线性模型 (如果成功拟合)
137 if(exists("exp_nlme") && !is.null(exp_nlme)) {
138   model_comparison <- rbind(model_comparison,

```

```

139         data.frame(Model = "指数模型",
140                     AIC = AIC(exp_nlme),
141                     BIC = BIC(exp_nlme),
142                     LogLik = logLik(exp_nlme)))
143     }
144
145     if(exists("logistic_nlme") && !is.null(logistic_nlme)) {
146         model_comparison <- rbind(model_comparison,
147                                   data.frame(Model = "Logistic 模型",
148                                               AIC = AIC(logistic_nlme),
149                                               BIC = BIC(logistic_nlme),
150                                               LogLik = logLik(logistic_nlme)))
151     }
152
153     if(exists("gompertz_nlme") && !is.null(gompertz_nlme)) {
154         model_comparison <- rbind(model_comparison,
155                                   data.frame(Model = "Gompertz 模型",
156                                               AIC = AIC(gompertz_nlme),
157                                               BIC = BIC(gompertz_nlme),
158                                               LogLik = logLik(gompertz_nlme)))
159     }
160
161     if(exists("gamm_model") && !is.null(gamm_model)) {
162         model_comparison <- rbind(model_comparison,
163                                   data.frame(Model = "GAMM 模型",
164                                               AIC = AIC(gamm_model),
165                                               BIC = BIC(gamm_model),
166                                               LogLik = logLik(gamm_model)))
167     }
168
169     # 显示模型比较结果
170     print("模型比较结果:")
171     print(model_comparison)
172
173     # 可视化拟合结果
174     # 创建预测函数
175     predict_nlme <- function(model, newdata) {
176         if(inherits(model, "nlme")) {
177             return(predict(model, newdata = newdata, level = 0))
178         } else if(inherits(model, "lmerMod")) {
179             return(predict(model, newdata = newdata, re.form = NA))
180         } else if(inherits(model, "bam")) {
181             return(predict(model, newdata = newdata, exclude = "s(Subject)"))
182         } else {
183             return(rep(NA, nrow(newdata)))
184         }
185     }
186
187     # 生成预测数据 - 修复: 使用平均BMI值
188     pred_data <- data.frame(
189         BMI = rep(mean(data$BMI), 100), # 使用平均BMI值
190         Gestational_days = seq(min(data$Gestational_days), max(data$Gestational_days), length.out = 100),
191         Subject = rep(levels(data$Subject)[1], 100) # 使用第一个受试者
192     )
193

```



```

194 # 为每个模型生成预测
195 pred_data$lmm <- predict_nlme(lmm_model, pred_data)
196
197 if(exists("exp_nlme") && !is.null(exp_nlme)) {
198   pred_data$exp <- predict_nlme(exp_nlme, pred_data)
199 }
200
201 if(exists("logistic_nlme") && !is.null(logistic_nlme)) {
202   pred_data$logistic <- predict_nlme(logistic_nlme, pred_data)
203 }
204
205 if(exists("gompertz_nlme") && !is.null(gompertz_nlme)) {
206   pred_data$gompertz <- predict_nlme(gompertz_nlme, pred_data)
207 }
208
209 if(exists("gamm_model") && !is.null(gamm_model)) {
210   pred_data$gamm <- predict_nlme(gamm_model, pred_data)
211 }
212
213 # 创建每个模型的拟合图
214 plots <- list()
215
216 # 线性混合模型
217 plots[[1]] <- ggplot() +
218   geom_point(data = data, aes(x = Gestational_days, y = Y_concentration, color = Subject), alpha = 0.6)
219   +
220   geom_line(data = pred_data, aes(x = Gestational_days, y = lmm, color = "总体拟合"), size = 1) +
221   theme_minimal() +
222   labs(title = "线性混合模型拟合", x = "孕周(天)", y = "Y染色体浓度")
223
224 # 指数模型
225 if(exists("exp_nlme") && !is.null(exp_nlme)) {
226   plots[[2]] <- ggplot() +
227     geom_point(data = data, aes(x = Gestational_days, y = Y_concentration, color = Subject), alpha =
228       0.6) +
229     geom_line(data = pred_data, aes(x = Gestational_days, y = exp, color = "总体拟合"), size = 1) +
230     theme_minimal() +
231     labs(title = "指数模型拟合", x = "孕周(天)", y = "Y染色体浓度")
232 }
233
234 # Logistic模型
235 if(exists("logistic_nlme") && !is.null(logistic_nlme)) {
236   plots[[3]] <- ggplot() +
237     geom_point(data = data, aes(x = Gestational_days, y = Y_concentration, color = Subject), alpha =
238       0.6) +
239     geom_line(data = pred_data, aes(x = Gestational_days, y = logistic, color = "总体拟合"), size = 1) +
240     theme_minimal() +
241     labs(title = "Logistic模型拟合", x = "孕周(天)", y = "Y染色体浓度")
242 }
243
244 # Gompertz模型
245 if(exists("gompertz_nlme") && !is.null(gompertz_nlme)) {
246   plots[[4]] <- ggplot() +
247     geom_point(data = data, aes(x = Gestational_days, y = Y_concentration, color = Subject), alpha =
248       0.6) +

```

```

245   geom_line(data = pred_data, aes(x = Gestational_days, y = gompertz, color = "总体拟合"), size = 1) +
246   theme_minimal() +
247   labs(title = "Gompertz模型拟合", x = "孕周(天)", y = "Y染色体浓度")
248 }
249
250 # GAMM模型
251 if(exists("gamm_model") && !is.null(gamm_model)) {
252   plots[[5]] <- ggplot() +
253     geom_point(data = data, aes(x = Gestational_days, y = Y_concentration, color = Subject), alpha =
254       0.6) +
255     geom_line(data = pred_data, aes(x = Gestational_days, y = gamm, color = "总体拟合"), size = 1) +
256     theme_minimal() +
257     labs(title = "GAMM模型拟合", x = "孕周(天)", y = "Y染色体浓度")
258 }
259
260 # 保存所有图表
261 for(i in seq_along(plots)) {
262   ggsave(paste0("model_fit_", i, ".png"), plots[[i]], width = 10, height = 6, dpi = 300)
263 }
264
265 # 创建模型比较图
266 model_comp_plot <- ggplot(model_comparison, aes(x = reorder(Model, AIC), y = AIC, fill = Model)) +
267   geom_bar(stat = "identity") +
268   theme_minimal() +
269   labs(title = "模型比较 - AIC值", x = "模型", y = "AIC值") +
270   theme(axis.text.x = element_text(angle = 45, hjust = 1)) +
271   scale_fill_brewer(palette = "Set2")
272
273 ggsave("model_comparison_aic.png", model_comp_plot, width = 10, height = 6, dpi = 300)
274
275 # 残差分析
276 residual_plots <- list()
277
278 # 线性混合模型残差
279 residual_plots[[1]] <- ggplot(data, aes(x = fitted(lmm_model), y = resid(lmm_model))) +
280   geom_point(alpha = 0.6) +
281   geom_hline(yintercept = 0, linetype = "dashed") +
282   theme_minimal() +
283   labs(title = "线性混合模型残差图", x = "拟合值", y = "残差")
284
285 # 指数模型残差
286 if(exists("exp_nlme") && !is.null(exp_nlme)) {
287   residual_plots[[2]] <- ggplot(data, aes(x = fitted(exp_nlme), y = resid(exp_nlme))) +
288     geom_point(alpha = 0.6) +
289     geom_hline(yintercept = 0, linetype = "dashed") +
290     theme_minimal() +
291     labs(title = "指数模型残差图", x = "拟合值", y = "残差")
292 }
293
294 # GAMM模型残差
295 if(exists("gamm_model") && !is.null(gamm_model)) {
296   residual_plots[[3]] <- ggplot(data, aes(x = fitted(gamm_model), y = resid(gamm_model))) +
297     geom_point(alpha = 0.6) +
298     geom_hline(yintercept = 0, linetype = "dashed") +
299     theme_minimal() +

```

```

299     labs(title = "GAMM模型残差图", x = "拟合值", y = "残差")
300 }
301
302 # 保存残差图
303 for(i in seq_along(residual_plots)) {
304     ggsave(paste0("residual_plot_", i, ".png"), residual_plots[[i]], width = 10, height = 6, dpi = 300)
305 }
306
307 # 输出模型摘要
308 sink("model_summaries.txt")
309 cat("\n线性混合模型摘要:\n")
310 print(summary(lmm_model))
311
312 if(exists("exp_nlme") && !is.null(exp_nlme)) {
313     cat("\n指数模型摘要:\n")
314     print(summary(exp_nlme))
315 }
316
317 if(exists("logistic_nlme") && !is.null(logistic_nlme)) {
318     cat("\nLogistic模型摘要:\n")
319     print(summary(logistic_nlme))
320 }
321
322 if(exists("gompertz_nlme") && !is.null(gompertz_nlme)) {
323     cat("\nGompertz模型摘要:\n")
324     print(summary(gompertz_nlme))
325 }
326
327 if(exists("gamm_model") && !is.null(gamm_model)) {
328     cat("\nGAMM模型摘要:\n")
329     print(summary(gamm_model))
330 }
331
332 cat("\n模型比较:\n")
333 print(model_comparison)
334 sink()
335
336 # 显示最佳模型
337 if(nrow(model_comparison) > 0) {
338     best_model_idx <- which.min(model_comparison$AIC)
339     cat("根据AIC准则, 最佳模型是:", model_comparison$Model[best_model_idx], "\n")
340
341 # 绘制最佳模型拟合图
342 if(model_comparison$Model[best_model_idx] == "线性混合模型") {
343     best_plot <- plots[[1]]
344 } else if(model_comparison$Model[best_model_idx] == "指数模型") {
345     best_plot <- plots[[2]]
346 } else if(model_comparison$Model[best_model_idx] == "Logistic模型") {
347     best_plot <- plots[[3]]
348 } else if(model_comparison$Model[best_model_idx] == "Gompertz模型") {
349     best_plot <- plots[[4]]
350 } else if(model_comparison$Model[best_model_idx] == "GAMM模型") {
351     best_plot <- plots[[5]]
352 }
353

```

```

354 ggsave("best_model_fit.png", best_plot, width = 10, height = 6, dpi = 300)
355 }
356
357 # 保存工作空间
358 save.image("mixed_model_analysis.RData")
359
360 cat("分析完成！所有结果已保存到当前工作目录。\\n")

```

Listing 2: C(2)(权重计算).py

```

1  import pandas as pd
2  import numpy as np
3  import matplotlib.pyplot as plt
4  from scipy import stats
5
6  plt.rcParams["font.sans-serif"] = ["SimHei", "Arial Unicode MS", "DejaVu Sans"]
7  plt.rcParams["axes.unicode_minus"] = False
8
9
10 def calculate_ahp_weights(matrix):
11
12     n = matrix.shape[0]
13
14     row_geom_mean = np.prod(matrix, axis=1) ** (1 / n)
15
16     weights = row_geom_mean / np.sum(row_geom_mean)
17
18     aw = np.dot(matrix, weights)
19     lambda_max = np.mean(aw / weights)
20
21     ci = (lambda_max - n) / (n - 1)
22
23     ri_table = {
24         1: 0,
25         2: 0,
26         3: 0.58,
27         4: 0.90,
28         5: 1.12,
29         6: 1.24,
30         7: 1.32,
31         8: 1.41,
32         9: 1.45,
33         10: 1.49,
34     }
35     ri = ri_table.get(n, 1.51)
36
37     cr = ci / ri if ri != 0 else 0
38
39     return weights, cr
40
41
42 def generate_stacked_bmi_mixed_charts_with_ahp_weights():
43     judgment_matrix = np.array([[1, 4, 6], [1 / 4, 1, 2], [1 / 6, 1 / 2, 1]])
44
45     category_order = ["always_can", "middle", "cannot"]

```

```

46
47     ahp_weights, cr = calculate_ahp_weights(judgment_matrix)
48
49     print("--- AHP 权重计算结果 ---")
50     print(f"判断矩阵:\n{judgment_matrix}\n")
51     print("计算出的权重向量:")
52     for i, category in enumerate(category_order):
53         print(f"    - {category}: {ahp_weights[i]:.4f}")
54
55     print(f"\n一致性指标 CI: {cr*0.58:.4f}")
56     print(f"一致性比率 CR: {cr:.4f}")
57     if cr < 0.1:
58         print(" -> 判断矩阵具有满意的一致性 (CR < 0.1)。")
59     else:
60         print(" -> 警告: 判断矩阵的一致性较差 (CR >= 0.1), 建议调整比较值。")
61     print("-" * 28 + "\n")
62
63     objective_weights_dict = {
64         category: weight for category, weight in zip(category_order, ahp_weights)
65     }
66
67     df_middle = pd.read_excel("./python_code/bmi_Y_middle_result.xlsx")
68     df_cannot_test = pd.read_excel("./python_code/bmi_Y_cannot_test_result.xlsx")
69     df_always_can_test = pd.read_excel(
70         "./python_code/bmi_Y_always_can_test_result.xlsx"
71     )
72
73     df_middle["category"] = "middle"
74     df_cannot_test["category"] = "cannot"
75     df_always_can_test["category"] = "always_can"
76
77     df_all = pd.concat(
78         [df_middle, df_cannot_test, df_always_can_test], ignore_index=True
79     )
80
81     df_all["days_raw"] = 0
82     df_all.loc[df_all["category"] == "cannot", "days_raw"] = df_all["最晚不达标天数"]
83     df_all.loc[df_all["category"] == "middle", "days_raw"] = df_all["预测达标天数"]
84     df_all.loc[df_all["category"] == "always_can", "days_raw"] = df_all["最早达标天数"]
85
86     def categorize_bmi(bmi):
87         if bmi < 30.17:
88             return "<30.17"
89         elif 30.17 <= bmi < 32.25:
90             return "30.17-32.25"
91         elif 32.25 <= bmi < 34.70:
92             return "32.25-34.70"
93         elif 34.70 <= bmi < 37.11:
94             return "34.70-37.11"
95         else:
96             return ">37.11"
97
98     df_all["bmi_category"] = df_all["BMI"].apply(categorize_bmi)
99
100    df_all["weight"] = df_all["category"].map(objective_weights_dict)

```

```

101
102 bmi_categories = ["<30.17", "30.17-32.25", "32.25-34.70", "34.70-37.11", ">37.11"]
103
104 stacking_order = ["cannot", "middle", "always_can"]
105 colors = {"cannot": "lightcoral", "middle": "goldenrod", "always_can": "seagreen"}
106 labels = {"cannot": "不能达标", "middle": "中间达标", "always_can": "始终达标"}
107
108 for bmi_cat in bmi_categories:
109     df_bmi = df_all[df_all["bmi_category"] == bmi_cat]
110
111     if df_bmi.empty:
112         continue
113
114     fig, ax1 = plt.subplots(figsize=(12, 8))
115
116     all_days_raw = df_bmi["days_raw"].tolist()
117
118     stacked_data, stacked_labels, stacked_colors = [], [], []
119     for category in stacking_order:
120         days = df_bmi[df_bmi["category"] == category]["days_raw"].tolist()
121         if days:
122             stacked_data.append(days)
123             stacked_labels.append(labels[category])
124             stacked_colors.append(colors[category])
125
126     if stacked_data:
127         data_range = max(all_days_raw) - min(all_days_raw) if all_days_raw else 0
128         bins_count = (
129             min(100, max(50, int(data_range / 3))) if data_range > 0 else 50
130         )
131         ax1.hist(
132             stacked_data,
133             bins=bins_count,
134             stacked=True,
135             color=stacked_colors,
136             label=stacked_labels,
137             alpha=0.95,
138             edgecolor="black",
139             linewidth=0.1,
140         )
141
142         ax1.set_xlabel("天数", fontsize=12)
143         ax1.set_ylabel("人数", fontsize=12)
144         ax1.set_title(f"BMI 区间 {bmi_cat} 分布 (AHP 业务逻辑权重)", fontsize=14)
145         ax1.legend(loc="upper left", fontsize=10)
146         ax1.grid(True, alpha=0.3)
147
148     if len(all_days_raw) > 1:
149         ax2 = ax1.twinx()
150         days_for_kde = df_bmi["days_raw"].to_numpy()
151         weights_for_kde = df_bmi["weight"].to_numpy()
152
153         try:
154             weighted_kde = stats.gaussian_kde(days_for_kde, weights=weights_for_kde)
155             x_range = np.linspace(min(all_days_raw), max(all_days_raw), 1000)

```

```

156         kde_values = weighted_kde(x_range)
157
158         ax2.plot(
159             x_range,
160             kde_values,
161             color="dodgerblue",
162             linewidth=2,
163             linestyle="--",
164             label="AHP 加权概率密度",
165         )
166         ax2.set_ylabel("加权概率密度", fontsize=12)
167         ax2.legend(loc="upper right", fontsize=10)
168
169         cumulative_prob = np.cumsum(kde_values) * (x_range[1] - x_range[0])
170         prob_levels = [0.85, 0.90, 0.95]
171         for prob in prob_levels:
172             try:
173                 index = np.where(cumulative_prob >= prob)[0][0]
174                 day_value = x_range[index]
175                 ax2.axvline(
176                     x=day_value, color="purple", linestyle="--", linewidth=1
177                 )
178                 ax2.text(
179                     day_value + 0.5,
180                     max(kde_values) * (1 - prob),
181                     f"{int(prob*100)}% -> {day_value:.1f}天",
182                     color="purple",
183                     rotation=90,
184                 )
185             except IndexError:
186                 pass
187
188         except Exception as e:
189             print(f"BMI 区间 {bmi_cat} 计算加权概率密度时出错: {e}")
190
191         plt.tight_layout()
192         filename = f'./python_code/BMI_{bmi_cat.replace("<", "lt").replace(">", "gt").replace("-", "_")}
193             _AHP_weighted_dist.png'
194         plt.savefig(filename, dpi=300, bbox_inches="tight")
195         plt.close()
196
197     generate_stacked_bmi_mixed_charts_with_ahp_weights()

```

Listing 3: C(2)(生存函数).py

```

1  import pandas as pd
2  import numpy as np
3  import matplotlib.pyplot as plt
4  from lifelines import KaplanMeierFitter
5  from scipy.optimize import minimize_scalar
6
7  plt.rcParams["font.sans-serif"] = ["SimHei", "Arial Unicode MS", "DejaVu Sans"]
8  plt.rcParams["axes.unicode_minus"] = False
9

```

```

10
11 def analyze_with_dynamic_utility():
12     def get_rearly(t):
13         return 2.0 * np.exp(-t / 50)
14
15     def get_rlate(t):
16         if t < 84:
17             return 0.1
18         elif t <= 189:
19             normalized_t = (t - 84) / (189 - 84)
20             return 0.1 + 0.9 * (normalized_t**2)
21         else:
22             return 1.0
23
24     def calculate_utility(t, survival_func):
25         if t < 0:
26             return float("inf")
27         closest_time_idx = np.abs(survival_func.index - t).argmin()
28         actual_time = survival_func.index[closest_time_idx]
29         p_t = 1 - survival_func.loc[actual_time, "s_t"]
30         return (1 - p_t) * get_rearly(t) + p_t * get_rlate(t)
31
32     df_middle = pd.read_excel("./python_code/bmi_Y_middle_result.xlsx")
33     df_cannot_test = pd.read_excel("./python_code/bmi_Y_cannot_test_result.xlsx")
34     df_always_can_test = pd.read_excel(
35         "./python_code/bmi_Y_always_can_test_result.xlsx"
36     )
37
38     df_all = pd.concat(
39         [
40             df_middle.assign(category="middle"),
41             df_cannot_test.assign(category="cannot"),
42             df_always_can_test.assign(category="always_can"),
43         ],
44         ignore_index=True,
45     )
46
47     df_all["duration"] = 0.0
48     df_all["event_observed"] = 0
49
50     df_all.loc[df_all["category"] == "cannot", "duration"] = df_all["最晚不达标天数"]
51     df_all.loc[df_all["category"] == "cannot", "event_observed"] = 0
52
53     df_all.loc[df_all["category"] == "middle", "duration"] = df_all["预测达标天数"]
54     df_all.loc[df_all["category"] == "middle", "event_observed"] = 1
55
56     df_all.loc[df_all["category"] == "always_can", "duration"] = 0.1
57     df_all.loc[df_all["category"] == "always_can", "event_observed"] = 1
58
59     def categorize_bmi(bmi):
60         if bmi < 30.26:
61             return "<30.26"
62         elif 30.26 <= bmi < 32.30:
63             return "30.26-32.30"
64         elif 32.30 <= bmi < 34.92:

```



```

65         return "32.30-34.92"
66     elif 34.92 <= bmi < 39.49:
67         return "34.92-39.49"
68     else:
69         return ">39.49"
70
71 df_all["bmi_category"] = df_all["BMI"].apply(categorize_bmi)
72
73 bmi_categories = ["<30.26", "30.26-32.30", "32.30-34.92", "34.92-39.49", ">39.49"]
74
75 results_table = []
76
77 for bmi_cat in bmi_categories:
78     df_bmi = df_all[df_all["bmi_category"] == bmi_cat].copy()
79
80     if df_bmi.empty:
81         results_table.append(
82             {
83                 "BMI分组": bmi_cat,
84                 "最优时点(天)": "无数据",
85                 "最小效用值": "无数据",
86                 "风险水平": "无数据",
87                 "样本量": 0,
88             }
89         )
90         continue
91
92     print(f"--- 正在分析 BMI 区间: {bmi_cat} ---")
93
94     kmf = KaplanMeierFitter()
95     kmf.fit(durations=df_bmi["duration"], event_observed=df_bmi["event_observed"])
96
97     s_t = kmf.survival_function_.rename(columns={"KM_estimate": "s_t"})
98
99     def objective(t):
100         return calculate_utility(t, s_t)
101
102     result = minimize_scalar(
103         objective, bounds=(0, df_bmi["duration"].max()), method="bounded"
104     )
105
106     optimal_time = result.x
107     optimal_utility = result.fun
108     risk_level = 1 / optimal_utility if optimal_utility > 0 else float("inf")
109     sample_size = len(df_bmi)
110
111     print(f"\n最优预测时间点分析:")
112     print(f" - 最优时间点: {optimal_time:.1f} 天")
113     print(f" - 最小效用值: {optimal_utility:.4f}")
114     print(f" - 风险水平: {risk_level:.4f}")
115     print(f" - 样本量: {sample_size}")
116
117     plt.figure(figsize=(14, 8))
118     ax = plt.gca()
119

```

```

120 (1 - kmf.survival_function_).plot(
121     ax=ax,
122     label=f"累积达标函数 F(t) ({bmi_cat})",
123     color="seagreen",
124     linewidth=2.5,
125 )
126
127 time_points = np.linspace(0, df_bmi["duration"].max(), 200)
128 utilities = [calculate_utility(t, s_t) for t in time_points]
129 ax_twin = ax.twinx()
130 ax_twin.plot(
131     time_points, utilities, "--", color="red", label="效用函数 E(t)", alpha=0.6
132 )
133
134 ax_twin.axvline(x=optimal_time, color="purple", linestyle="--", linewidth=1)
135 ax_twin.text(
136     optimal_time + 2,
137     min(utilities) + 0.1,
138     f"最优时间点: {optimal_time:.1f}天\n效用值: {optimal_utility:.3f}",
139     color="purple",
140     fontsize=10,
141 )
142
143 ax.axvspan(0, 84, facecolor="green", alpha=0.15, label="早期阶段 (<84天)")
144 ax.axvspan(84, 189, facecolor="orange", alpha=0.15, label="过渡阶段 (84-189天)")
145 ax.axvspan(
146     189,
147     df_all["duration"].max() + 10,
148     facecolor="red",
149     alpha=0.15,
150     label="晚期阶段 (>189天)",
151 )
152
153 ax.set_title(f"BMI区间 {bmi_cat} 达标情况与效用分析", fontsize=16)
154 ax.set_xlabel("天数", fontsize=12)
155 ax.set_ylabel("累积达标比例", fontsize=12)
156 ax_twin.set_ylabel("效用值", fontsize=12)
157
158 lines1, labels1 = ax.get_legend_handles_labels()
159 lines2, labels2 = ax_twin.get_legend_handles_labels()
160 ax.legend(lines1 + lines2, labels1 + labels2, loc="upper left")
161
162 ax.grid(True, alpha=0.3)
163 ax.set_ylim(0, 1.05)
164 ax_twin.set_ylim(0, max(utilities) * 1.2)
165 ax.set_xlim(-5, df_all["duration"].max() + 10)
166
167 filename = f'./python_code/BMI_{bmi_cat.replace("<", "lt").replace(">", "gt").replace("-", "_")}_utility_analysis.png'
168 plt.savefig(filename, dpi=300, bbox_inches="tight")
169 plt.close()
170
171 results_table.append(
172     {
173         "BMI分组": bmi_cat,

```

```

174         "最优时点(天)": f"{optimal_time:.1f}",
175         "最小效用值": f"{optimal_utility:.4f}",
176         "风险水平": f"{risk_level:.4f}",
177         "样本量": sample_size,
178     }
179 )
180
181 print(f"\n图表已保存至: {filename}")
182 print("\n" + "=" * 50 + "\n")
183
184 print("\n\n=== 各BMI分组NIPT时点计算结果 ===")
185 print("BMI分组\t\t最优时点(天)\t\t最小效用值\t\t风险水平\t\t样本量")
186 print("-" * 70)
187
188 for result in results_table:
189     print(
190         f"{result['BMI分组']}\t\t{result['最优时点(天)']}\t\t{result['最小效用值']}\t\t{result['风险水平']}\t\t{result['样本量']}"
191     )
192
193 results_df = pd.DataFrame(results_table)
194 results_df.to_excel("./python_code/NIPT_optimal_times_results.xlsx", index=False)
195 print(f"\n结果表格已保存至: ./python_code/NIPT_optimal_times_results.xlsx")
196
197 return results_df
198
199
200 results = analyze_with_dynamic_utility()

```

Listing 4: C(2)(正态分布检验).py

```

1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
4 import matplotlib.font_manager as fm
5 from matplotlib import rcParams
6 from scipy import stats
7 import re
8
9 plt.rcParams["font.sans-serif"] = ["SimHei", "Arial Unicode MS", "DejaVu Sans"]
10 plt.rcParams["axes.unicode_minus"] = False
11
12
13 def categorize_bmi(bmi):
14     if bmi < 30:
15         return "<30"
16     elif 30 <= bmi < 32:
17         return "30-32"
18     elif 32 <= bmi < 34:
19         return "32-34"
20     elif 34 <= bmi < 36:
21         return "34-36"
22     else:
23         return ">36"
24

```

```

25
26 def normality_test_and_plot_with_qq():
27     df_middle = pd.read_excel("./python_code/bmi_Y_middle_result.xlsx")
28     df_cannot_test = pd.read_excel("./python_code/bmi_Y_cannot_test_result.xlsx")
29     df_always_can_test = pd.read_excel(
30         "./python_code/bmi_Y_always_can_test_result.xlsx"
31     )
32
33     df_middle["bmi_category"] = df_middle["BMI"].apply(categorize_bmi)
34     df_cannot_test["bmi_category"] = df_cannot_test["BMI"].apply(categorize_bmi)
35     df_always_can_test["bmi_category"] = df_always_can_test["BMI"].apply(categorize_bmi)
36
37     bmi_categories = ["<30", "30-32", "32-34", "34-36", ">36"]
38
39     colors = {"cannot": "red", "middle": "yellow", "always_can": "green"}
40     labels = {"cannot": "不能达标", "middle": "中间达标", "always_can": "始终达标"}
41
42     for bmi_cat in bmi_categories:
43         df_cannot = df_cannot_test[df_cannot_test["bmi_category"] == bmi_cat]
44         df_middle_cat = df_middle[df_middle["bmi_category"] == bmi_cat]
45         df_always = df_always_can_test[df_always_can_test["bmi_category"] == bmi_cat]
46
47         days_cannot = (
48             df_cannot["最晚不达标天数"].tolist() if not df_cannot.empty else []
49         )
50         days_middle = (
51             df_middle_cat["预测达标天数"].tolist() if not df_middle_cat.empty else []
52         )
53         days_always = df_always["最早达标天数"].tolist() if not df_always.empty else []
54
55         all_days = days_cannot + days_middle + days_always
56
57         if not all_days:
58             print(f"警告: BMI 区间 {bmi_cat} 没有数据")
59             continue
60
61         data = np.array(all_days)
62
63         print(f"\n=== BMI 区间 {bmi_cat} 的正态分布检验 ===")
64         print(f"样本数量: {len(data)}")
65
66         if len(data) <= 5000:
67             try:
68                 shapiro_stat, shapiro_p = stats.shapiro(data)
69                 print(
70                     f"Shapiro-Wilk 检验: 统计量={shapiro_stat:.6f}, p 值={shapiro_p:.6f}"
71                 )
72                 if shapiro_p > 0.05:
73                     print(" 结论: 数据符合正态分布 (p > 0.05)")
74                 else:
75                     print(" 结论: 数据不符合正态分布 (p <= 0.05)")
76             except Exception as e:
77                 print(f"Shapiro-Wilk 检验失败: {e}")
78         else:
79             print("Shapiro-Wilk 检验: 样本量过大(>5000), 跳过该检验")

```

```

80
81     try:
82         jb_stat, jb_p = stats.jarque_bera(data)
83         print(f"Jarque-Bera 检验: 统计量={jb_stat:.6f}, p 值={jb_p:.6f}")
84         if jb_p > 0.05:
85             print(" 结论: 数据符合正态分布 (p > 0.05)")
86         else:
87             print(" 结论: 数据不符合正态分布 (p <= 0.05)")
88     except Exception as e:
89         print(f"Jarque-Bera 检验失败: {e}")
90
91     mean = np.mean(data)
92     std = np.std(data)
93     print(f"数据均值: {mean:.2f}, 标准差: {std:.2f}")
94
95     plt.figure(figsize=(12, 8))
96
97     data_to_plot = []
98     plot_labels = []
99     plot_colors = []
100
101     if days_cannot:
102         data_to_plot.append(days_cannot)
103         plot_labels.append(labels["cannot"])
104         plot_colors.append(colors["cannot"])
105
106     if days_middle:
107         data_to_plot.append(days_middle)
108         plot_labels.append(labels["middle"])
109         plot_colors.append(colors["middle"])
110
111     if days_always:
112         data_to_plot.append(days_always)
113         plot_labels.append(labels["always_can"])
114         plot_colors.append(colors["always_can"])
115
116     if data_to_plot:
117         n, bins, patches = plt.hist(
118             data_to_plot,
119             bins=20,
120             stacked=True,
121             color=plot_colors,
122             label=plot_labels,
123             alpha=0.7,
124             edgecolor="black",
125             linewidth=0.3,
126         )
127
128     is_normal = False
129     if len(data) <= 5000 and "shapiro_p" in locals() and shapiro_p > 0.05:
130         is_normal = True
131     elif len(data) > 5000 and "jb_p" in locals() and jb_p > 0.05:
132         is_normal = True
133     elif (
134         len(data) <= 5000

```

```

135     and "shapiro_p" not in locals()
136     and "jb_p" in locals()
137     and jb_p > 0.05
138 ):
139     is_normal = True
140
141 if is_normal:
142     x = np.linspace(min(data), max(data), 1000)
143     y = stats.norm.pdf(x, mean, std)
144     bin_width = bins[1] - bins[0]
145     y_scaled = y * len(data) * bin_width
146
147     plt.plot(
148         x,
149         y_scaled,
150         "b-",
151         linewidth=2,
152         label=f"正态分布拟合 (={mean:.1f}, ={std:.1f})",
153     )
154
155     print(" 已在图中绘制正态分布拟合曲线")
156 else:
157     print(" 数据不符合正态分布，未绘制正态分布曲线")
158
159 plt.xlabel("天数", fontsize=14, fontweight="bold")
160 plt.ylabel("人数", fontsize=14, fontweight="bold")
161 plt.title(
162     f"BMI区间 {bmi_cat} 的孕妇Y染色体达标情况分布及正态分布检验",
163     fontsize=16,
164     fontweight="bold",
165 )
166 plt.legend(fontsize=12)
167 plt.grid(True, alpha=0.3)
168
169 plt.xticks(fontsize=12)
170 plt.yticks(fontsize=12)
171
172 plt.tight_layout()
173 normal_suffix = "_normal" if is_normal else "_non_normal"
174 plt.savefig(
175     f'./python_code/BMI_{bmi_cat.replace("<", "lt").replace(">", "gt")}_stacked_with_normal_test'
176     f'{normal_suffix}.png',
177     dpi=300,
178     bbox_inches="tight",
179 )
180 plt.close()
181
182 plt.figure(figsize=(10, 8))
183
184 stats.probplot(data, dist="norm", plot=plt)
185 plt.title(f"BMI区间 {bmi_cat} 的Q-Q图", fontsize=16, fontweight="bold")
186 plt.xlabel("理论分位数", fontsize=14)
187 plt.ylabel("样本分位数", fontsize=14)
188 plt.grid(True, alpha=0.3)

```

```

189     plt.xticks(fontsize=12)
190     plt.yticks(fontsize=12)
191
192     theoretical_quantiles, sample_quantiles = stats.probplot(data, dist="norm")
193     slope, intercept, r_value, p_value, std_err = stats.linregress(
194         theoretical_quantiles[0], theoretical_quantiles[1]
195     )
196     r_squared = r_value**2
197
198     plt.text(
199         0.05,
200         0.95,
201         f"R² = {r_squared:.4f}",
202         transform=plt.gca().transAxes,
203         fontsize=12,
204         verticalalignment="top",
205         bbox=dict(boxstyle="round", facecolor="white", alpha=0.8),
206     )
207
208     plt.tight_layout()
209     plt.savefig(
210         f'./python_code/BMI_{bmi_cat.replace("<", "lt").replace(">", "gt")}_qq_plot.png',
211         dpi=300,
212         bbox_inches="tight",
213     )
214     plt.close()
215
216     print(f" 已生成Q-Q图 (R² = {r_squared:.4f})")
217
218     print(f"BMI区间 {bmi_cat} 详细统计:")
219     print(f" 不能达标: {len(df_cannot)} 人")
220     print(f" 中间达标: {len(df_middle_cat)} 人")
221     print(f" 始终达标: {len(df_always)} 人")
222     print(f" 总计: {len(data)} 人")
223
224
225 if __name__ == "__main__":
226     normality_test_and_plot_with_qq()
227
228     print("\n正态分布检验、直方图和Q-Q图生成完成!")

```

Listing 5: C(2) 测试误差.py

```

1  import pandas as pd
2  import numpy as np
3  import matplotlib.pyplot as plt
4  from lifelines import KaplanMeierFitter
5  from scipy.optimize import minimize_scalar
6  from scipy.stats import norm
7  import re
8
9  plt.rcParams["font.sans-serif"] = ["SimHei", "Arial Unicode MS", "DejaVu Sans"]
10 plt.rcParams["axes.unicode_minus"] = False
11
12

```

```

13 def analyze_with_error_simulation(num_simulations=100, error_std=0.01):
14     # 定义效用函数 (与之前相同)
15     def get_rearly(t):
16         return 2.0 * np.exp(-t / 50)
17
18     def get_rlate(t):
19         if t < 84:
20             return 0.1
21         elif t <= 189:
22             normalized_t = (t - 84) / (189 - 84)
23             return 0.1 + 0.9 * (normalized_t**2)
24         else:
25             return 1.0
26
27     def calculate_utility(t, survival_func):
28         if t < 0:
29             return float("inf")
30         closest_time_idx = np.abs(survival_func.index - t).argmin()
31         actual_time = survival_func.index[closest_time_idx]
32         p_t = 1 - survival_func.loc[actual_time, "s_t"]
33         return (1 - p_t) * get_rearly(t) + p_t * get_rlate(t)
34
35     # 辅助函数: 清理文件名中的非法字符
36     def clean_filename(name):
37         # 替换文件名字符串中的非法字符
38         return re.sub(r'[\<>:"/\|?*]', "_", name)
39
40     # 加载数据
41     df_middle = pd.read_excel("./python_code/bmi_Y_middle_result.xlsx")
42     df_cannot_test = pd.read_excel("./python_code/bmi_Y_cannot_test_result.xlsx")
43     df_always_can_test = pd.read_excel(
44         "./python_code/bmi_Y_always_can_test_result.xlsx"
45     )
46
47     df_all = pd.concat(
48         [
49             df_middle.assign(category="middle"),
50             df_cannot_test.assign(category="cannot"),
51             df_always_can_test.assign(category="always_can"),
52         ],
53         ignore_index=True,
54     )
55
56     df_all["duration"] = 0.0
57     df_all["event_observed"] = 0
58
59     df_all.loc[df_all["category"] == "cannot", "duration"] = df_all["最晚不达标天数"]
60     df_all.loc[df_all["category"] == "cannot", "event_observed"] = 0
61
62     df_all.loc[df_all["category"] == "middle", "duration"] = df_all["预测达标天数"]
63     df_all.loc[df_all["category"] == "middle", "event_observed"] = 1
64
65     df_all.loc[df_all["category"] == "always_can", "duration"] = 0.1
66     df_all.loc[df_all["category"] == "always_can", "event_observed"] = 1
67

```



```

68 def categorize_bmi(bmi):
69     if bmi < 30.26:
70         return "<30.26"
71     elif 30.26 <= bmi < 32.30:
72         return "30.26-32.30"
73     elif 32.30 <= bmi < 34.92:
74         return "32.30-34.92"
75     elif 34.92 <= bmi < 39.49:
76         return "34.92-39.49"
77     else:
78         return ">39.49"
79
80 df_all["bmi_category"] = df_all["BMI"].apply(categorize_bmi)
81 bmi_categories = ["<30.26", "30.26-32.30", "32.30-34.92", "34.92-39.49", ">39.49"]
82
83 results = {
84     bmi_cat: {"times": [], "utilities": [], "risks": []}
85     for bmi_cat in bmi_categories
86 }
87
88 original_results = {}
89 for bmi_cat in bmi_categories:
90     df_bmi = df_all[df_all["bmi_category"] == bmi_cat].copy()
91     if df_bmi.empty:
92         continue
93
94     kmf = KaplanMeierFitter()
95     kmf.fit(durations=df_bmi["duration"], event_observed=df_bmi["event_observed"])
96     s_t = kmf.survival_function_.rename(columns={"KM_estimate": "s_t"})
97
98     def objective(t):
99         return calculate_utility(t, s_t)
100
101     result = minimize_scalar(
102         objective, bounds=(0, df_bmi["duration"].max()), method="bounded"
103     )
104
105     original_time = result.x
106     original_utility = result.fun
107     original_risk = 1 / original_utility if original_utility > 0 else float("inf")
108
109     original_results[bmi_cat] = {
110         "time": original_time,
111         "utility": original_utility,
112         "risk": original_risk,
113     }
114
115     print(f"BMI 区间 {bmi_cat} 原始结果:")
116     print(f"    最优时点: {original_time:.2f} 天")
117     print(f"    最小效用值: {original_utility:.4f}")
118     print(f"    风险水平: {original_risk:.4f}")
119
120 # 开始模拟
121 for simulation in range(num_simulations):
122     print(f"正在进行第 {simulation+1} 次模拟...")

```

```

123
124     df_simulated = df_all.copy()
125     np.random.seed(simulation)
126
127     mask_middle = df_simulated["category"] == "middle"
128     mask_always = df_simulated["category"] == "always_can"
129
130     if sum(mask_middle) > 0:
131         error_middle = np.random.normal(
132             0,
133             error_std * df_simulated.loc[mask_middle, "预测达标天数"].mean(),
134             size=sum(mask_middle),
135         )
136         df_simulated.loc[mask_middle, "duration"] += error_middle
137
138     if sum(mask_always) > 0:
139         error_always = np.random.normal(
140             0,
141             error_std * df_simulated.loc[mask_always, "最早达标天数"].mean(),
142             size=sum(mask_always),
143         )
144         df_simulated.loc[mask_always, "duration"] += error_always
145
146     mask_cannot = df_simulated["category"] == "cannot"
147     if sum(mask_cannot) > 0:
148         error_cannot = np.random.normal(
149             0,
150             error_std * df_simulated.loc[mask_cannot, "最晚不达标天数"].mean(),
151             size=sum(mask_cannot),
152         )
153         df_simulated.loc[mask_cannot, "duration"] += error_cannot
154
155     df_simulated["duration"] = df_simulated["duration"].clip(lower=0.1)
156
157     for bmi_cat in bmi_categories:
158         df_bmi = df_simulated[df_simulated["bmi_category"] == bmi_cat].copy()
159         if df_bmi.empty:
160             continue
161
162         kmf = KaplanMeierFitter()
163         kmf.fit(
164             durations=df_bmi["duration"], event_observed=df_bmi["event_observed"]
165         )
166         s_t = kmf.survival_function_.rename(columns={"KM_estimate": "s_t"})
167
168         def objective(t):
169             return calculate_utility(t, s_t)
170
171         result = minimize_scalar(
172             objective, bounds=(0, df_bmi["duration"].max()), method="bounded"
173         )
174
175         optimal_time = result.x
176         optimal_utility = result.fun
177         risk = 1 / optimal_utility if optimal_utility > 0 else float("inf")

```

```

178         results[bmi_cat]["times"].append(optimal_time)
179         results[bmi_cat]["utilities"].append(optimal_utility)
180         results[bmi_cat]["risks"].append(risk)
181
182
183     print("\n=== 检测误差影响分析 ===")
184     for bmi_cat in bmi_categories:
185         if results[bmi_cat]["times"]:
186             times = np.array(results[bmi_cat]["times"])
187             utilities = np.array(results[bmi_cat]["utilities"])
188             risks = np.array(results[bmi_cat]["risks"])
189
190             mean_time = times.mean()
191             std_time = times.std()
192             time_confidence_interval = norm.interval(
193                 0.95, loc=mean_time, scale=std_time / np.sqrt(len(times))
194             )
195
196             mean_utility = utilities.mean()
197             std_utility = utilities.std()
198
199             mean_risk = risks.mean()
200             std_risk = risks.std()
201
202             original_time = original_results.get(bmi_cat, {}).get("time", 0)
203             original_utility = original_results.get(bmi_cat, {}).get("utility", 0)
204             original_risk = original_results.get(bmi_cat, {}).get("risk", 0)
205
206             print(f"BMI 区间 {bmi_cat}:")
207             print(f"  原始最优时点: {original_time:.2f} 天")
208             print(f"  模拟最优时点均值: {mean_time:.2f} 天")
209             print(f"  标准差: {std_time:.2f} 天")
210             print(
211                 f"  95%置信区间: ({time_confidence_interval[0]:.2f}, {time_confidence_interval[1]:.2f})"
212                 f"  天"
213             )
214             print(f"  原始最小效用值: {original_utility:.4f}")
215             print(f"  模拟最小效用值均值: {mean_utility:.4f}")
216             print(f"  效用值标准差: {std_utility:.4f}")
217             print(f"  原始风险水平: {original_risk:.4f}")
218             print(f"  模拟风险水平均值: {mean_risk:.4f}")
219             print(f"  风险水平标准差: {std_risk:.4f}")
220
221             plt.figure(figsize=(12, 8))
222
223             plt.subplot(2, 2, 1)
224             plt.hist(times, bins=20, alpha=0.7, edgecolor="black")
225             plt.axvline(
226                 mean_time,
227                 color="r",
228                 linestyle="--",
229                 label=f"模拟平均时点: {mean_time:.2f}",
230             )
231             plt.axvline(
232                 original_time,

```

```

232         color="b",
233         linestyle="-",
234         label=f"原始最优时点: {original_time:.2f}",
235     )
236     plt.axvline(
237         time_confidence_interval[0],
238         color="g",
239         linestyle=":",
240         label="95%置信区间",
241     )
242     plt.axvline(time_confidence_interval[1], color="g", linestyle=":")
243     plt.xlabel("最优NIPT时点 (天)")
244     plt.ylabel("频数")
245     plt.title(f"BMI区间 {bmi_cat} - 最优时点分布")
246     plt.legend()
247     plt.grid(True, alpha=0.3)
248
249     plt.subplot(2, 2, 2)
250     plt.hist(utilities, bins=20, alpha=0.7, edgecolor="black", color="orange")
251     plt.axvline(
252         mean_utility,
253         color="r",
254         linestyle="--",
255         label=f"模拟平均效用值: {mean_utility:.4f}",
256     )
257     plt.axvline(
258         original_utility,
259         color="b",
260         linestyle="-",
261         label=f"原始最小效用值: {original_utility:.4f}",
262     )
263     plt.xlabel("最小效用值")
264     plt.ylabel("频数")
265     plt.title(f"BMI区间 {bmi_cat} - 最小效用值分布")
266     plt.legend()
267     plt.grid(True, alpha=0.3)
268
269     plt.subplot(2, 2, 3)
270     plt.scatter(times, utilities, alpha=0.6)
271     plt.axvline(original_time, color="b", linestyle="-", label="原始最优时点")
272     plt.axhline(
273         original_utility, color="b", linestyle="-", label="原始最小效用值"
274     )
275     plt.xlabel("最优时点 (天)")
276     plt.ylabel("最小效用值")
277     plt.title(f"BMI区间 {bmi_cat} - 时点与效用值关系")
278     plt.legend()
279     plt.grid(True, alpha=0.3)
280
281     plt.subplot(2, 2, 4)
282     plt.hist(risks, bins=20, alpha=0.7, edgecolor="black", color="red")
283     plt.axvline(
284         mean_risk,
285         color="r",
286         linestyle="--",

```

```

287         label=f"模拟平均风险: {mean_risk:.4f}",
288     )
289     plt.axvline(
290         original_risk,
291         color="b",
292         linestyle="-",
293         label=f"原始风险: {original_risk:.4f}",
294     )
295     plt.xlabel("风险水平")
296     plt.ylabel("频数")
297     plt.title(f"BMI 区间 {bmi_cat} - 风险水平分布")
298     plt.legend()
299     plt.grid(True, alpha=0.3)
300
301     plt.tight_layout()
302
303     safe_bmi_cat = clean_filename(bmi_cat)
304     filename = f"./python_code/error_analysis_BMI_{safe_bmi_cat}.png"
305     plt.savefig(filename, dpi=300, bbox_inches="tight")
306     plt.close()
307
308     data_df = pd.DataFrame({"time": times, "utility": utilities, "risk": risks})
309     csv_filename = f"./python_code/error_analysis_BMI_{safe_bmi_cat}.csv"
310     data_df.to_csv(csv_filename, index=False)
311
312     print(f" 图表已保存至: {filename}")
313     print(f" 数据已保存至: {csv_filename}")
314 else:
315     print(f"BMI 区间 {bmi_cat}: 无数据")
316
317
318 analyze_with_error_simulation(num_simulations=100, error_std=0.05)

```

Listing 6: C(2) 分类画图.py

```

1  import pandas as pd
2  import numpy as np
3  import matplotlib.pyplot as plt
4  import matplotlib.font_manager as fm
5  from matplotlib import rcParams
6  from scipy import stats
7  import re
8
9
10 plt.rcParams["font.sans-serif"] = ["SimHei", "Arial Unicode MS", "DejaVu Sans"]
11 plt.rcParams["axes.unicode_minus"] = False
12
13
14 def best_bmi_Y():
15     def weeks_to_days(weeks_str):
16         match = re.match(r"(\d+)[wW](?:\+(\d+))?", str(weeks_str), re.IGNORECASE)
17         if match:
18             weeks = int(match.group(1))
19             days = int(match.group(2)) if match.group(2) else 0
20             return weeks * 7 + days

```

```

21     else:
22         print(f"无法解析孕周格式: {weeks_str}")
23         return None
24
25 df = pd.read_excel("./python_code/附件.xlsx", sheet_name=0)
26 df = df[["孕妇代码", "检测孕周", "孕妇BMI", "Y染色体浓度"]]
27 bmi_avg = df.groupby("孕妇代码")["孕妇BMI"].mean()
28 df["孕妇平均BMI"] = df["孕妇代码"].map(bmi_avg)
29 df["检测孕周_天数"] = df["检测孕周"].apply(weeks_to_days)
30
31 # print(df)
32 code_col = "孕妇代码"
33 day_col = "检测孕周_天数"
34 bmi_col = "孕妇平均BMI"
35 y_col = "Y染色体浓度"
36 # df_can_test_codes = df[df[y_col] >= 0.04][code_col].unique() # not left
37 # df_cannot_test_codes = df[~df[code_col].isin(df_can_test_codes)][code_col].unique() # left
38 # df_codes_cannot_test_before_codes = df[df[y_col] < 0.04][code_col].unique() # not right
39 # df_always_can_test_codes = df[~df[code_col].isin(df_codes_cannot_test_before_codes)][code_col].
    unique() # right
40 # df_middle_codes = np.setdiff1d(df_can_test_codes, df_always_can_test_codes)
41 df_codes = df[code_col].unique()
42
43 result_middle = []
44 result_cannot_test = []
45 result_always_can_test = []
46 for code in df_codes:
47     data = df[df[code_col] == code].sort_values(by=day_col)
48     mean_bmi = data[bmi_col].mean()
49     first_ok_idx = None
50     for idx, row in data.iterrows():
51         if row[y_col] >= 0.04:
52             first_ok_idx = idx
53             break
54
55     if first_ok_idx is None:
56         result_cannot_test.append(
57             {code_col: code, "BMI": mean_bmi, "最晚不达标天数": data[day_col].max()}
58         )
59         continue
60     else:
61         later_data = data.loc[first_ok_idx:]
62         if (later_data[y_col] < 0.04).any():
63             continue
64         else:
65             if first_ok_idx == data.index[0]:
66                 result_always_can_test.append(
67                     {
68                         code_col: code,
69                         "BMI": mean_bmi,
70                         "最早达标天数": data[day_col].min(),
71                     }
72                 )
73             else:
74                 ok_row = data.loc[first_ok_idx]

```

```

75         prev_row = data.loc[
76             data.index[data.index.get_loc(first_ok_idx) - 1]
77         ]
78
79         w1 = abs(ok_row[y_col] - 0.04)
80         w2 = abs(prev_row[y_col] - 0.04)
81         predicted_day = (w2 * ok_row[day_col] + w1 * prev_row[day_col]) / (
82             w1 + w2
83         )
84         result_middle.append(
85             {code_col: code, "BMI": mean_bmi, "预测达标天数": predicted_day}
86         )
87
88     df_middle = pd.DataFrame(result_middle)
89     df_cannot_test = pd.DataFrame(result_cannot_test)
90     df_always_can_test = pd.DataFrame(result_always_can_test)
91
92     df_middle.to_excel("./python_code/bmi_Y_middle_result.xlsx", index=False)
93     df_cannot_test.to_excel("./python_code/bmi_Y_cannot_test_result.xlsx", index=False)
94     df_always_can_test.to_excel(
95         "./python_code/bmi_Y_always_can_test_result.xlsx", index=False
96     )
97
98
99 def generate_bmi_category_charts():
100     df_middle = pd.read_excel("./python_code/bmi_Y_middle_result.xlsx")
101     df_cannot_test = pd.read_excel("./python_code/bmi_Y_cannot_test_result.xlsx")
102     df_always_can_test = pd.read_excel(
103         "./python_code/bmi_Y_always_can_test_result.xlsx"
104     )
105
106     df_middle["category"] = "middle"
107     df_cannot_test["category"] = "cannot"
108     df_always_can_test["category"] = "always_can"
109
110     df_all = pd.concat(
111         [df_middle, df_cannot_test, df_always_can_test], ignore_index=True
112     )
113
114     def categorize_bmi(bmi):
115         if bmi < 30:
116             return "<30"
117         elif 30 <= bmi < 32:
118             return "30-32"
119         elif 32 <= bmi < 34:
120             return "32-34"
121         elif 34 <= bmi < 36:
122             return "34-36"
123         else:
124             return ">36"
125
126     df_all["bmi_category"] = df_all["BMI"].apply(categorize_bmi)
127
128     bmi_categories = ["<30", "30-32", "32-34", "34-36", ">36"]
129

```

```

130 categories = ["cannot", "middle", "always_can"]
131 colors = {"cannot": "red", "middle": "yellow", "always_can": "green"}
132 labels = {"cannot": "不能达标", "middle": "中间达标", "always_can": "始终达标"}
133
134 for bmi_cat in bmi_categories:
135     df_bmi = df_all[df_all["bmi_category"] == bmi_cat]
136
137     if df_bmi.empty:
138         print(f"警告: BMI区间 {bmi_cat} 没有数据")
139         continue
140
141     plt.figure(figsize=(12, 8))
142
143     for category in categories:
144         df_category = df_bmi[df_bmi["category"] == category]
145
146         if not df_category.empty:
147             if category == "cannot":
148                 days = df_category["最晚不达标天数"]
149             elif category == "middle":
150                 days = df_category["预测达标天数"]
151             else:
152                 days = df_category["最早达标天数"]
153
154             plt.hist(
155                 days,
156                 bins=20,
157                 alpha=0.7,
158                 color=colors[category],
159                 label=labels[category],
160                 edgecolor="black",
161                 linewidth=0.5,
162             )
163
164     plt.xlabel("天数", fontsize=12)
165     plt.ylabel("人数", fontsize=12)
166     plt.title(f"BMI区间 {bmi_cat} 的孕妇Y染色体达标情况分布", fontsize=14)
167     plt.legend(fontsize=10)
168     plt.grid(True, alpha=0.3)
169
170     plt.savefig(
171         f'./python_code/BMI_{bmi_cat.replace("<", "lt").replace(">", "gt")}_distribution.png',
172         dpi=300,
173         bbox_inches="tight",
174     )
175     plt.close()
176
177     print(f"BMI区间 {bmi_cat} 统计:")
178     for category in categories:
179         count = len(df_bmi[df_bmi["category"] == category])
180         print(f"    {labels[category]}: {count} 人")
181     print()
182
183
184 def generate_bmi_mixed_charts():

```



```

185
186 df_middle = pd.read_excel("./python_code/bmi_Y_middle_result.xlsx")
187 df_cannot_test = pd.read_excel("./python_code/bmi_Y_cannot_test_result.xlsx")
188 df_always_can_test = pd.read_excel(
189     "./python_code/bmi_Y_always_can_test_result.xlsx"
190 )
191
192 df_middle["category"] = "middle"
193 df_cannot_test["category"] = "cannot"
194 df_always_can_test["category"] = "always_can"
195
196 df_all = pd.concat(
197     [df_middle, df_cannot_test, df_always_can_test], ignore_index=True
198 )
199
200 def categorize_bmi(bmi):
201     if bmi < 30:
202         return "<30"
203     elif 30 <= bmi < 32:
204         return "30-32"
205     elif 32 <= bmi < 34:
206         return "32-34"
207     elif 34 <= bmi < 36:
208         return "34-36"
209     else:
210         return ">36"
211
212 df_all["bmi_category"] = df_all["BMI"].apply(categorize_bmi)
213
214 bmi_categories = ["<30", "30-32", "32-34", "34-36", ">36"]
215
216 categories = ["cannot", "middle", "always_can"]
217 colors = {"cannot": "red", "middle": "yellow", "always_can": "green"}
218 labels = {"cannot": "不能达标", "middle": "中间达标", "always_can": "始终达标"}
219
220 for bmi_cat in bmi_categories:
221     df_bmi = df_all[df_all["bmi_category"] == bmi_cat]
222
223     if df_bmi.empty:
224         print(f"警告: BMI 区间 {bmi_cat} 没有数据")
225         continue
226
227     fig, ax1 = plt.subplots(figsize=(12, 8))
228
229     all_days = []
230
231     for category in categories:
232         df_category = df_bmi[df_bmi["category"] == category]
233
234         if not df_category.empty:
235             if category == "cannot":
236                 days = df_category["最晚不达标天数"]
237             elif category == "middle":
238                 days = df_category["预测达标天数"]
239             else:

```

```

240         days = df_category["最早达标天数"]
241
242         ax1.hist(
243             days,
244             bins=20,
245             alpha=0.7,
246             color=colors[category],
247             label=labels[category],
248             edgecolor="black",
249             linewidth=0.5,
250         )
251
252         all_days.extend(days.tolist())
253
254     ax1.set_xlabel("天数", fontsize=12)
255     ax1.set_ylabel("人数", fontsize=12)
256     ax1.set_title(f"BMI 区间 {bmi_cat} 的孕妇Y染色体达标情况分布", fontsize=14)
257     ax1.legend(fontsize=10)
258     ax1.grid(True, alpha=0.3)
259
260     if len(all_days) > 1:
261         ax2 = ax1.twinx()
262
263         try:
264             kde = stats.gaussian_kde(all_days)
265             x_range = np.linspace(min(all_days), max(all_days), 1000)
266             kde_values = kde(x_range)
267
268             ax2.plot(
269                 x_range,
270                 kde_values,
271                 color="blue",
272                 linewidth=2,
273                 linestyle="--",
274                 label="总体概率密度",
275             )
276
277             ax2.set_ylabel("概率密度", fontsize=12)
278             ax2.legend(loc="upper right", fontsize=10)
279         except Exception as e:
280             print(f"BMI 区间 {bmi_cat} 计算概率密度时出错: {e}")
281
282     plt.tight_layout()
283
284     plt.savefig(
285         f'./python_code/BMI_{bmi_cat.replace("<", "lt").replace(">", "gt")}_distribution.png',
286         dpi=300,
287         bbox_inches="tight",
288     )
289     plt.close()
290
291     print(f"BMI 区间 {bmi_cat} 统计:")
292     total_count = len(df_bmi)
293     for category in categories:
294         count = len(df_bmi[df_bmi["category"] == category])

```

```

295         percentage = (count / total_count) * 100 if total_count > 0 else 0
296         print(f" {labels[category]}: {count} 人 ({percentage:.1f}%)")
297     print(f" 总计: {total_count} 人")
298     print()
299
300
301 def generate_stacked_bmi_charts_alternative():
302     df_middle = pd.read_excel("./python_code/bmi_Y_middle_result.xlsx")
303     df_cannot_test = pd.read_excel("./python_code/bmi_Y_cannot_test_result.xlsx")
304     df_always_can_test = pd.read_excel(
305         "./python_code/bmi_Y_always_can_test_result.xlsx"
306     )
307
308     def categorize_bmi(bmi):
309         if bmi < 30:
310             return "<30"
311         elif 30 <= bmi < 32:
312             return "30-32"
313         elif 32 <= bmi < 34:
314             return "32-34"
315         elif 34 <= bmi < 36:
316             return "34-36"
317         else:
318             return ">36"
319
320     df_middle["bmi_category"] = df_middle["BMI"].apply(categorize_bmi)
321     df_cannot_test["bmi_category"] = df_cannot_test["BMI"].apply(categorize_bmi)
322     df_always_can_test["bmi_category"] = df_always_can_test["BMI"].apply(categorize_bmi)
323
324     bmi_categories = ["<30", "30-32", "32-34", "34-36", ">36"]
325
326     colors = {"cannot": "red", "middle": "yellow", "always_can": "green"}
327     labels = {"cannot": "不能达标", "middle": "中间达标", "always_can": "始终达标"}
328     category_order = ["cannot", "middle", "always_can"]
329
330     for bmi_cat in bmi_categories:
331         df_cannot = df_cannot_test[df_cannot_test["bmi_category"] == bmi_cat]
332         df_middle_cat = df_middle[df_middle["bmi_category"] == bmi_cat]
333         df_always = df_always_can_test[df_always_can_test["bmi_category"] == bmi_cat]
334
335         if df_cannot.empty and df_middle_cat.empty and df_always.empty:
336             print(f"警告: BMI区间 {bmi_cat} 没有数据")
337             continue
338
339         plt.figure(figsize=(12, 8))
340
341         days_cannot = (
342             df_cannot["最晚不达标天数"].tolist() if not df_cannot.empty else []
343         )
344         days_middle = (
345             df_middle_cat["预测达标天数"].tolist() if not df_middle_cat.empty else []
346         )
347         days_always = df_always["最早达标天数"].tolist() if not df_always.empty else []
348
349         all_days = days_cannot + days_middle + days_always

```

```

350     if not all_days:
351         print(f"警告: BMI 区间 {bmi_cat} 没有有效数据")
352         continue
353
354     bins = np.linspace(min(all_days), max(all_days), 21)
355     data_to_plot = []
356     plot_labels = []
357     plot_colors = []
358
359     if days_cannot:
360         data_to_plot.append(days_cannot)
361         plot_labels.append(labels["cannot"])
362         plot_colors.append(colors["cannot"])
363
364     if days_middle:
365         data_to_plot.append(days_middle)
366         plot_labels.append(labels["middle"])
367         plot_colors.append(colors["middle"])
368
369     if days_always:
370         data_to_plot.append(days_always)
371         plot_labels.append(labels["always_can"])
372         plot_colors.append(colors["always_can"])
373
374     if data_to_plot:
375         plt.hist(
376             data_to_plot,
377             bins=bins,
378             stacked=True,
379             color=plot_colors,
380             label=plot_labels,
381             alpha=0.7,
382             edgecolor="black",
383             linewidth=0.3,
384         )
385
386     plt.xlabel("天数", fontsize=14, fontweight="bold")
387     plt.ylabel("人数", fontsize=14, fontweight="bold")
388     plt.title(
389         f"BMI 区间 {bmi_cat} 的孕妇Y染色体达标情况分布",
390         fontsize=16,
391         fontweight="bold",
392     )
393     plt.legend(fontsize=12)
394     plt.grid(True, alpha=0.3)
395
396     plt.xticks(fontsize=12)
397     plt.yticks(fontsize=12)
398
399     plt.tight_layout()
400     plt.savefig(
401         f'./python_code/BMI_{bmi_cat.replace("<", "lt").replace(">", "gt")}_stacked_v2.png',
402         dpi=300,
403         bbox_inches="tight",
404     )

```

```

405     plt.close()
406
407     print(f"BMI 区间 {bmi_cat} 统计:")
408     print(f"    不能达标: {len(df_cannot)} 人")
409     print(f"    中间达标: {len(df_middle_cat)} 人")
410     print(f"    始终达标: {len(df_always)} 人")
411     print(f"    总计: {len(df_cannot) + len(df_middle_cat) + len(df_always)} 人")
412     print()
413
414
415 def categorize_bmi(bmi):
416     """根据BMI值分类"""
417     if bmi < 30:
418         return "<30"
419     elif 30 <= bmi < 32:
420         return "30-32"
421     elif 32 <= bmi < 34:
422         return "32-34"
423     elif 34 <= bmi < 36:
424         return "34-36"
425     else:
426         return ">36"
427
428
429 def normality_test_and_plot():
430     df_middle = pd.read_excel("./python_code/bmi_Y_middle_result.xlsx")
431     df_cannot_test = pd.read_excel("./python_code/bmi_Y_cannot_test_result.xlsx")
432     df_always_can_test = pd.read_excel(
433         "./python_code/bmi_Y_always_can_test_result.xlsx"
434     )
435
436     df_middle["bmi_category"] = df_middle["BMI"].apply(categorize_bmi)
437     df_cannot_test["bmi_category"] = df_cannot_test["BMI"].apply(categorize_bmi)
438     df_always_can_test["bmi_category"] = df_always_can_test["BMI"].apply(categorize_bmi)
439
440     bmi_categories = ["<30", "30-32", "32-34", "34-36", ">36"]
441
442     colors = {"cannot": "red", "middle": "yellow", "always_can": "green"}
443     labels = {"cannot": "不能达标", "middle": "中间达标", "always_can": "始终达标"}
444
445     for bmi_cat in bmi_categories:
446         df_cannot = df_cannot_test[df_cannot_test["bmi_category"] == bmi_cat]
447         df_middle_cat = df_middle[df_middle["bmi_category"] == bmi_cat]
448         df_always = df_always_can_test[df_always_can_test["bmi_category"] == bmi_cat]
449
450         days_cannot = (
451             df_cannot["最早不达标天数"].tolist() if not df_cannot.empty else []
452         )
453         days_middle = (
454             df_middle_cat["预测达标天数"].tolist() if not df_middle_cat.empty else []
455         )
456         days_always = df_always["最早达标天数"].tolist() if not df_always.empty else []
457
458         all_days = days_cannot + days_middle + days_always
459

```

```

460     if not all_days:
461         print(f"警告: BMI区间 {bmi_cat} 没有数据")
462         continue
463
464     data = np.array(all_days)
465
466     print(f"\n=== BMI区间 {bmi_cat} 的正态分布检验 ===")
467     print(f"样本数量: {len(data)}")
468
469     if len(data) <= 5000:
470         try:
471             shapiro_stat, shapiro_p = stats.shapiro(data)
472             print(
473                 f"Shapiro-Wilk检验: 统计量={shapiro_stat:.6f}, p值={shapiro_p:.6f}"
474             )
475             if shapiro_p > 0.05:
476                 print(" 结论: 数据符合正态分布 (p > 0.05)")
477             else:
478                 print(" 结论: 数据不符合正态分布 (p <= 0.05)")
479         except Exception as e:
480             print(f"Shapiro-Wilk检验失败: {e}")
481     else:
482         print("Shapiro-Wilk检验: 样本量过大(>5000), 跳过该检验")
483
484     try:
485         jb_stat, jb_p = stats.jarque_bera(data)
486         print(f"Jarque-Bera检验: 统计量={jb_stat:.6f}, p值={jb_p:.6f}")
487         if jb_p > 0.05:
488             print(" 结论: 数据符合正态分布 (p > 0.05)")
489         else:
490             print(" 结论: 数据不符合正态分布 (p <= 0.05)")
491     except Exception as e:
492         print(f"Jarque-Bera检验失败: {e}")
493
494     mean = np.mean(data)
495     std = np.std(data)
496     print(f"数据均值: {mean:.2f}, 标准差: {std:.2f}")
497
498     plt.figure(figsize=(12, 8))
499
500     data_to_plot = []
501     plot_labels = []
502     plot_colors = []
503
504     if days_cannot:
505         data_to_plot.append(days_cannot)
506         plot_labels.append(labels["cannot"])
507         plot_colors.append(colors["cannot"])
508
509     if days_middle:
510         data_to_plot.append(days_middle)
511         plot_labels.append(labels["middle"])
512         plot_colors.append(colors["middle"])
513
514     if days_always:

```

```

515     data_to_plot.append(days_always)
516     plot_labels.append(labels["always_can"])
517     plot_colors.append(colors["always_can"])
518
519     if data_to_plot:
520         n, bins, patches = plt.hist(
521             data_to_plot,
522             bins=20,
523             stacked=True,
524             color=plot_colors,
525             label=plot_labels,
526             alpha=0.7,
527             edgecolor="black",
528             linewidth=0.3,
529         )
530
531     is_normal = False
532     if len(data) <= 5000 and "shapiro_p" in locals() and shapiro_p > 0.05:
533         is_normal = True
534     elif len(data) > 5000 and "jb_p" in locals() and jb_p > 0.05:
535         is_normal = True
536     elif (
537         len(data) <= 5000
538         and "shapiro_p" not in locals()
539         and "jb_p" in locals()
540         and jb_p > 0.05
541     ):
542         is_normal = True
543
544     if is_normal:
545         x = np.linspace(min(data), max(data), 1000)
546         y = stats.norm.pdf(x, mean, std)
547         bin_width = bins[1] - bins[0]
548         y_scaled = y * len(data) * bin_width
549
550         plt.plot(
551             x,
552             y_scaled,
553             "b-",
554             linewidth=2,
555             label=f"正态分布拟合 (={mean:.1f}, ={std:.1f})",
556         )
557
558         print(" 已在图中绘制正态分布拟合曲线")
559     else:
560         print(" 数据不符合正态分布，未绘制正态分布曲线")
561
562     plt.xlabel("天数", fontsize=14, fontweight="bold")
563     plt.ylabel("人数", fontsize=14, fontweight="bold")
564     plt.title(
565         f"BMI区间 {bmi_cat} 的孕妇Y染色体达标情况分布及正态分布检验",
566         fontsize=16,
567         fontweight="bold",
568     )
569     plt.legend(fontsize=12)

```

```

570     plt.grid(True, alpha=0.3)
571
572     plt.xticks(fontsize=12)
573     plt.yticks(fontsize=12)
574
575     plt.tight_layout()
576     normal_suffix = "_normal" if is_normal else "_non_normal"
577     plt.savefig(
578         f'./python_code/BMI_{bmi_cat.replace("<", "lt").replace(">", "gt")}_stacked_with_normal_test'
579         f'{normal_suffix}.png',
580         dpi=300,
581         bbox_inches="tight",
582     )
583     plt.close()
584
585     print(f"BMI 区间 {bmi_cat} 详细统计:")
586     print(f"    不能达标: {len(df_cannot)} 人")
587     print(f"    中间达标: {len(df_middle_cat)} 人")
588     print(f"    始终达标: {len(df_always)} 人")
589     print(f"    总计: {len(data)} 人")
590
591 def generate_stacked_bmi_mixed_charts():
592     df_middle = pd.read_excel("./python_code/bmi_Y_middle_result.xlsx")
593     df_cannot_test = pd.read_excel("./python_code/bmi_Y_cannot_test_result.xlsx")
594     df_always_can_test = pd.read_excel(
595         "./python_code/bmi_Y_always_can_test_result.xlsx"
596     )
597
598     df_middle["category"] = "middle"
599     df_cannot_test["category"] = "cannot"
600     df_always_can_test["category"] = "always_can"
601
602     df_all = pd.concat(
603         [df_middle, df_cannot_test, df_always_can_test], ignore_index=True
604     )
605
606     def categorize_bmi(bmi):
607         if bmi < 30.26:
608             return "<30.26"
609         elif 30.26 <= bmi < 32.30:
610             return "30.26-32.30"
611         elif 32.30 <= bmi < 34.92:
612             return "32.30-34.92"
613         elif 34.92 <= bmi < 39.49:
614             return "34.92-39.49"
615         else:
616             return ">39.49"
617
618     df_all["bmi_category"] = df_all["BMI"].apply(categorize_bmi)
619
620     bmi_categories = ["<30.26", "30.26-32.30", "32.30-34.92", "34.92-39.49", ">39.49"]
621
622     categories = ["cannot", "middle", "always_can"]
623     colors = {"cannot": "lightcoral", "middle": "gold", "always_can": "seagreen"}

```



```

624 labels = {"cannot": "不能达标", "middle": "中间达标", "always_can": "始终达标"}
625
626 for bmi_cat in bmi_categories:
627     df_bmi = df_all[df_all["bmi_category"] == bmi_cat]
628
629     if df_bmi.empty:
630         print(f"警告: BMI区间 {bmi_cat} 没有数据")
631         continue
632
633     fig, ax1 = plt.subplots(figsize=(12, 8))
634
635     all_days = []
636
637     days_data = {}
638     for category in categories:
639         df_category = df_bmi[df_bmi["category"] == category]
640
641         if not df_category.empty:
642             if category == "cannot":
643                 days = df_category["最晚不达标天数"].tolist()
644             elif category == "middle":
645                 days = df_category["预测达标天数"].tolist()
646             else:
647                 days = df_category["最早达标天数"].tolist()
648
649             days_data[category] = days
650             all_days.extend(days)
651
652     stacked_data = []
653     stacked_labels = []
654     stacked_colors = []
655
656     if "cannot" in days_data:
657         stacked_data.append(days_data["cannot"])
658         stacked_labels.append(labels["cannot"])
659         stacked_colors.append(colors["cannot"])
660
661     if "middle" in days_data:
662         stacked_data.append(days_data["middle"])
663         stacked_labels.append(labels["middle"])
664         stacked_colors.append(colors["middle"])
665
666     if "always_can" in days_data:
667         stacked_data.append(days_data["always_can"])
668         stacked_labels.append(labels["always_can"])
669         stacked_colors.append(colors["always_can"])
670
671     if stacked_data:
672         if len(all_days) > 0:
673             data_range = max(all_days) - min(all_days)
674             bins_count = min(100, max(50, int(data_range / 3)))
675         else:
676             bins_count = 50
677
678     n, bins, patches = ax1.hist(

```

```

679         stacked_data,
680         bins=bins_count,
681         stacked=True,
682         color=stacked_colors,
683         label=stacked_labels,
684         alpha=0.95,
685         edgecolor="black",
686         linewidth=0.1,
687     )
688
689     ax1.set_xlabel("天数", fontsize=12)
690     ax1.set_ylabel("人数", fontsize=12)
691     ax1.set_title(
692         f"BMI 区间 {bmi_cat} 的孕妇Y染色体达标情况分布 (堆叠图)", fontsize=14
693     )
694     ax1.legend(fontsize=10)
695     ax1.grid(True, alpha=0.3)
696
697     if len(all_days) > 1:
698         ax2 = ax1.twinx()
699
700         try:
701             kde = stats.gaussian_kde(all_days)
702             x_range = np.linspace(min(all_days), max(all_days), 1000)
703             kde_values = kde(x_range)
704
705             ax2.plot(
706                 x_range,
707                 kde_values,
708                 color="dodgerblue",
709                 linewidth=2,
710                 linestyle="-",
711                 label="总体概率密度",
712             )
713
714             ax2.set_ylabel("概率密度", fontsize=12)
715             ax2.legend(bbox_to_anchor=(1.0, 0.9), fontsize=10)
716         except Exception as e:
717             print(f"BMI 区间 {bmi_cat} 计算概率密度时出错: {e}")
718
719     plt.tight_layout()
720
721     filename = f'./python_code/BMI_{bmi_cat.replace("<", "lt").replace(">", "gt").replace("-", "_")}_stacked_distribution.png'
722     plt.savefig(filename, dpi=300, bbox_inches="tight")
723     plt.close()
724
725     print(f"BMI 区间 {bmi_cat} 统计:")
726     total_count = len(df_bmi)
727     for category in categories:
728         count = len(df_bmi[df_bmi["category"] == category])
729         percentage = (count / total_count) * 100 if total_count > 0 else 0
730         print(f" {labels[category]}: {count} 人 ({percentage:.1f}%)")
731     print(f" 总计: {total_count} 人")
732     print()

```

```

733
734
735 def generate_overall_stacked_bmi_chart():
736     df_middle = pd.read_excel("./python_code/bmi_Y_middle_result.xlsx")
737     df_cannot_test = pd.read_excel("./python_code/bmi_Y_cannot_test_result.xlsx")
738     df_always_can_test = pd.read_excel(
739         "./python_code/bmi_Y_always_can_test_result.xlsx"
740     )
741
742     df_middle["category"] = "middle"
743     df_cannot_test["category"] = "cannot"
744     df_always_can_test["category"] = "always_can"
745
746     df_all = pd.concat(
747         [df_middle, df_cannot_test, df_always_can_test], ignore_index=True
748     )
749
750     def categorize_bmi(bmi):
751         if bmi < 30.26:
752             return "<30.26"
753         elif 30.26 <= bmi < 32.30:
754             return "30.26-32.30"
755         elif 32.30 <= bmi < 34.92:
756             return "32.30-34.92"
757         elif 34.92 <= bmi < 39.49:
758             return "34.92-39.49"
759         else:
760             return ">39.49"
761
762     df_all["bmi_category"] = df_all["BMI"].apply(categorize_bmi)
763
764     bmi_categories = ["<30.26", "30.26-32.30", "32.30-34.92", "34.92-39.49", ">39.49"]
765
766     categories = ["cannot", "middle", "always_can"]
767     colors = {"cannot": "red", "middle": "yellow", "always_can": "green"}
768     labels = {"cannot": "不能达标", "middle": "中间达标", "always_can": "始终达标"}
769
770     fig, ax1 = plt.subplots(figsize=(15, 8))
771
772     all_data_by_category = {cat: [] for cat in categories}
773
774     for bmi_cat in bmi_categories:
775         df_bmi = df_all[df_all["bmi_category"] == bmi_cat]
776
777         for category in categories:
778             df_category = df_bmi[df_bmi["category"] == category]
779
780             if not df_category.empty:
781                 if category == "cannot":
782                     days = df_category["最晚不达标天数"].tolist()
783                 elif category == "middle":
784                     days = df_category["预测达标天数"].tolist()
785                 else:
786                     days = df_category["最早达标天数"].tolist()
787

```

```

788         labeled_days = [(day, bmi_cat) for day in days]
789         all_data_by_category[category].extend(labeled_days)
790
791     x_positions = np.arange(len(bmi_categories))
792     bar_width = 0.6
793
794     bottom_values = np.zeros(len(bmi_categories))
795
796     for category in categories:
797         heights = []
798         for bmi_cat in bmi_categories:
799             count = len([x for x in all_data_by_category[category] if x[1] == bmi_cat])
800             heights.append(count)
801
802         ax1.bar(
803             x_positions,
804             heights,
805             bar_width,
806             bottom=bottom_values,
807             label=labels[category],
808             color=colors[category],
809             alpha=0.7,
810             edgecolor="black",
811             linewidth=0.5,
812         )
813
814         bottom_values = np.add(bottom_values, heights)
815
816     ax1.set_xlabel("BMI 区间", fontsize=12)
817     ax1.set_ylabel("人数", fontsize=12)
818     ax1.set_title("各BMI区间孕妇Y染色体达标情况分布（堆叠柱状图）", fontsize=14)
819     ax1.set_xticks(x_positions)
820     ax1.set_xticklabels(bmi_categories)
821     ax1.legend(fontsize=10)
822     ax1.grid(True, alpha=0.3, axis="y")
823
824     plt.tight_layout()
825
826     plt.savefig(
827         "./python_code/BMI_all_intervals_stacked_distribution_new.png",
828         dpi=300,
829         bbox_inches="tight",
830     )
831     plt.close()
832
833     print("总体堆叠柱状图已生成")
834
835
836 if __name__ == "__main__":
837     generate_overall_stacked_bmi_chart()
838     generate_stacked_bmi_mixed_charts()
839     print("\n图表生成完成!")

```

Listing 7: C(2) 聚类.py

```

1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
4 from sklearn.cluster import KMeans
5 from sklearn.preprocessing import StandardScaler
6 from sklearn.metrics import (
7     silhouette_score,
8     davies_bouldin_score,
9     calinski_harabasz_score,
10 )
11
12 plt.rcParams["font.sans-serif"] = ["SimHei"]
13 plt.rcParams["axes.unicode_minus"] = False
14
15
16 def perform_clustering(df, n_clusters=5):
17     X = df[["BMI"]].values
18     scaler = StandardScaler()
19     X_scaled = scaler.fit_transform(X)
20
21     kmeans = KMeans(n_clusters=n_clusters, random_state=42, n_init=10)
22     clusters = kmeans.fit_predict(X_scaled)
23
24     df["Cluster"] = clusters
25
26     centers_scaled = kmeans.cluster_centers_
27     centers_original = scaler.inverse_transform(centers_scaled)
28
29     return df, kmeans, scaler, centers_original, X_scaled
30
31
32 def evaluate_clustering(X, clusters):
33     silhouette_avg = silhouette_score(X, clusters)
34     dbi = davies_bouldin_score(X, clusters)
35     ch_index = calinski_harabasz_score(X, clusters)
36
37     print("\n聚类效果评估:")
38     print(f"轮廓系数 (Silhouette Score): {silhouette_avg:.4f}")
39     print(f"DBI指数 (Davies-Bouldin Index): {dbi:.4f}")
40     print(f"CH指数 (Calinski-Harabasz Index): {ch_index:.4f}")
41
42     return silhouette_avg, dbi, ch_index
43
44
45 def print_cluster_ranges(df):
46     print("\n各聚类的BMI范围:")
47     print("-" * 50)
48     for i in range(5):
49         cluster_data = df[df["Cluster"] == i][["BMI"]]
50         min_bmi = cluster_data.min()
51         max_bmi = cluster_data.max()
52         mean_bmi = cluster_data.mean()
53         count = len(cluster_data)
54
55         if mean_bmi < 18.5:

```

```

56         category = "偏瘦"
57     elif mean_bmi < 24:
58         category = "正常"
59     elif mean_bmi < 28:
60         category = "偏胖"
61     else:
62         category = "肥胖"
63
64     print(
65         f"聚类 {i}: {count:3d} 个样本, BMI范围: {min_bmi:.2f}--{max_bmi:.2f}, "
66         f"平均值: {mean_bmi:.2f} ({category})"
67     )
68
69     print("-" * 50)
70
71
72 def visualize_results(df, centers_original, silhouette_avg, dbi, ch_index):
73     fig, axes = plt.subplots(2, 2, figsize=(15, 12))
74
75     for i in range(5):
76         cluster_data = df[df["Cluster"] == i]["BMI"]
77         axes[0, 0].hist(cluster_data, alpha=0.6, bins=20, label=f"Cluster {i}")
78
79         axes[0, 0].axvline(x=18.5, color="r", linestyle="--", label="偏瘦阈值")
80         axes[0, 0].axvline(x=24, color="g", linestyle="--", label="正常阈值")
81         axes[0, 0].axvline(x=28, color="orange", linestyle="--", label="偏胖阈值")
82         axes[0, 0].set_xlabel("BMI")
83         axes[0, 0].set_ylabel("频数")
84         axes[0, 0].set_title("各聚类BMI分布")
85         axes[0, 0].legend()
86         axes[0, 0].grid(True, alpha=0.3)
87
88     cluster_labels = [f"Cluster {i}" for i in range(5)]
89     axes[0, 1].bar(
90         cluster_labels,
91         centers_original.flatten(),
92         color=["blue", "green", "red", "purple", "orange"],
93     )
94     axes[0, 1].set_ylabel("BMI值")
95     axes[0, 1].set_title("各聚类中心BMI值")
96     axes[0, 1].grid(True, alpha=0.3)
97
98     for i in range(5):
99         cluster_data = df[df["Cluster"] == i]
100         axes[1, 0].scatter(
101             cluster_data["BMI"],
102             cluster_data["对应达标天数"],
103             alpha=0.6,
104             label=f"Cluster {i}",
105         )
106
107     axes[1, 0].set_xlabel("BMI")
108     axes[1, 0].set_ylabel("达标天数")
109     axes[1, 0].set_title("BMI与达标天数的关系")
110     axes[1, 0].legend()

```

```

111     axes[1, 0].grid(True, alpha=0.3)
112
113
114 def save_results(df, centers_original, silhouette_avg, dbi, ch_index):
115     summary_data = {
116         "聚类编号": range(5),
117         "聚类中心(BMI)": centers_original.flatten(),
118         "样本数量": [len(df[df["Cluster"] == i]) for i in range(5)],
119         "BMI最小值": [df[df["Cluster"] == i]["BMI"].min() for i in range(5)],
120         "BMI最大值": [df[df["Cluster"] == i]["BMI"].max() for i in range(5)],
121         "BMI平均值": [df[df["Cluster"] == i]["BMI"].mean() for i in range(5)],
122     }
123     summary_df = pd.DataFrame(summary_data)
124
125     eval_df = pd.DataFrame(
126         {
127             "评估指标": ["轮廓系数", "DBI指数", "CH指数"],
128             "值": [silhouette_avg, dbi, ch_index],
129         }
130     )
131
132     with pd.ExcelWriter("聚类分析结果.xlsx") as writer:
133         df.to_excel(writer, sheet_name="原始数据与聚类结果", index=False)
134         summary_df.to_excel(writer, sheet_name="聚类摘要", index=False)
135         eval_df.to_excel(writer, sheet_name="评估指标", index=False)
136
137     print("\n结果已保存到 '聚类分析结果.xlsx'")
138
139
140 def main():
141     file_path = "python_code/bmi_Y_result.xlsx"
142     df = pd.read_excel(file_path)
143     df_result, kmeans, scaler, centers_original, X_scaled = perform_clustering(df)
144
145     silhouette_avg, dbi, ch_index = evaluate_clustering(
146         X_scaled, df_result["Cluster"].values
147     )
148
149     print_cluster_ranges(df_result)
150
151     visualize_results(df_result, centers_original, silhouette_avg, dbi, ch_index)
152
153     save_results(df_result, centers_original, silhouette_avg, dbi, ch_index)
154
155
156 if __name__ == "__main__":
157     main()

```